2026 年 10 月推理压缩洞察
从需求、实现到昇腾研究决策

部门：云核 · 推理压缩
日期： 2026-10-08



HUAWEI

报告范围：三类事实如何形成同一研究判断

热点资讯 → 需求背景： 3 条已核对原始信号，关注总参数 / 激活参数、真实总位宽、任务专用小模型。
产业进展 → 实现边界： 9 条本月核对的昇腾记录；当前已审阅范围没有确认 10 月新发布，不把旧版本当新版本。
学术进展 → 技术路线：复核 13 篇当月候选，按权重、激活、 KV Cache 及其方法关联组织。
报告正文 → 5 篇代表工作：覆盖权重量化、激活剪枝、 KV 量化、淘汰和低秩；代表性不等于均为最高优先级。
补充资料 → 5 篇图文附录 + 3 篇网页文字：同一对象内的补偿、编码、时机与结构变体按需阅读。

范围截至 2026-10-08， 10 月尚未结束；不是全年 / 全月穷尽覆盖。逐条事实在本期动态，本报告只选形成研究判断的证据。

â…¬à¼¿€è®ºæ–‡ Â· ç ”ç©¶â»è®®
HUAWEI

热点资讯：部署需求在变化，先识别预算对象

Mistral Large 4（10月6日官方公告）：1T总参数、52B激活参数；API预览已开放，权重计划月底发布。权重驻留与每token计算不能按同一个参数数目规划。

openTPU（10月1日作者实验记录）：4-bit加两级尺度实际为4.25 bit/weight，LM head为int8；分别报告device和wall速度。应比较总字节和端到端成本。

Strands Decider 2B（10月1日官方介绍）：Qwen3.5-2B改pointer head并用rank-16 LoRA，面向选项决策、不能通用生成。先判断任务专用小模型是否适合业务。

研究边界：这些是需求与度量信号，不是量化效果、剪枝 / 蒸馏实现或昇腾性能证据。

â…¬â¼€è®ºæ–‡ Â· ç "ç©¶â»è®®

HUAWEI

产业进展：昇腾能力已落到哪些格式、算子与运行栈

msModelSlim（10月8日核对、发布日未确认）：V1资料覆盖GPTQ/AWQ、SmoothQuant/FA3 Quant、KVCache Quant及组合；alpha02为内测版。导出格式仍须匹配模型与推理引擎。

ops-transformer（10月7日核对5—7月进展）：A5 MXFP8融合Attention、DSV4稀疏MLA/量化索引及量化Dense Attention；master尾块高精窗口仍需核对发布标签。

vLLM-Ascend（9月发布，10月7日核对）：v0.23.0.post1修复KV写入/量化缓冲；v0.27.1rc1接入MiniMax-M3低精度和DeepSeek-V4-Flash稀疏Attention，模型/硬件有明确限制。

CANN 9.1.1（10月7日核对、发布日未确认）：ops-transformer配套与旧量化/Attention API迁移须按表匹配；源码主干、文档能力与安装包支持不能混为一谈。

落地边界：本页为本月核对的既有实现，非 10 月新发布清单；官方支持、候选版本与主干变更均不等于昇腾本地实测。

â…¬à¼¿€è®ºæ–‡ Â· ç ”ç©¶â»è®®

HUAWEI

大类	技术名称	技术简介
权重	**AlignQuant**	权重 × 量化：二维 tile 统一混合精度、紧凑存储与 prefill/decode 执行。
激活	**SpAx**	激活 × 剪枝；关联权重 × 量化：小激活读取压缩权重，大激活读取原权重，近零激活跳过。
KV Cache	**TaSQ**	KV Cache × 量化：在 RoPE 前对 Key 加权、跨头归一化和相关通道分组，再向量量化。
KV Cache	**Page-EntroKV**	KV Cache × KV Cache 淘汰：按 GQA 共享组聚合重要性，映射页后淘汰，严格控制实际保留预算。
KV Cache	**AttSVD**	KV Cache × 低秩分解：提供累积与流式两种解码缓存策略。

â…¬â¼€è®ºæ–‡ Â· ç "ç©¶â»è®®

HUAWEI

AlignQuant: Tile-Aligned Mixed-Precision Quantization for Efficient LLM Generation （权重 × 量化）

参考： arXiv:2610.07457 v1 · Fig.2 / Table 1 · 2026-10-05

技术背景 北德克萨斯大学与圣路易斯大学团队针对混合精度边界和 GPU 执行单元错位，采用二维权重 tile 统一校准、打包与计算。研究价值是把模型变小与生成变快接起来，降低异构位宽的执行开销。

技术细节

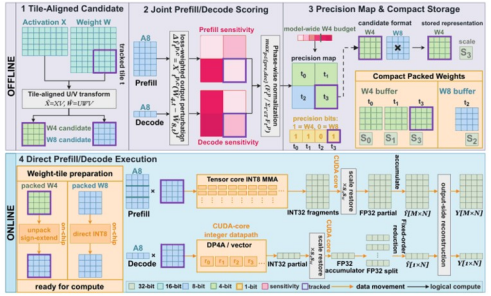


Figure 2: **Overview of *AlignQuant*.** Purple outlines track one logical weight tile. *(1) Candidates.* Tile-aligned U/V transforms prepare 4-bit and 8-bit weight candidates. *(2) Joint scoring.* Loss-weighted output changes score each 8-bit to 4-bit replacement in prefill and decode; the larger normalized score determines 8-bit priority. *(3) Compact storage.* The budget assigns 4-bit precision to the lowest-scoring tiles, storing one selected representation and scale per tile. *(4) Direct execution.* With 8-bit activations, prefill uses Tensor Core multiplication and decode uses DP4A dot products. The illustrated path expands 4-bit weights to INT8 on chip; long prefill reuses a temporary INT8 buffer. Scaled accumulation and output reconstruction produce Y.

共同粒度： 64×64 tile 选择 W4/W8 ， 使用 A8 输入。
联合校准： 综合 prefill/decode 敏感性，在全模型预算内分配位宽。
直接执行： W4 紧凑加载后展开为 INT8 ， 阶段专用核复用同一模型。

实验结果

平台： A100-SXM4 40GB ； 扩展至 H100 NVL 、 RTX 4090 。
模型： 主结果 Llama-3.2-3B ， 64×64 tile 、 60% W4 。
基线： BF16 及 GPTQ/AWQ 等；单次完整生成的 TTFT 、 TPOT 与容量。

Table 1: End-to-end inference efficiency for **Llama-3.2-3B-Instruct**. Cell colors are relative to BF16 under the corresponding metric direction: green for better than or equal to BF16, blue for worse than BF16, and gray for BF16. Bold and underlined values indicate the best and worst results, respectively, among the compared methods excluding the reference columns.

Metric	Unit	Upper Ref.	Lower Ref.	Ours	Others			
		BF16	W4A8	*AlignQuant*	GPTQ	AWQ	MixLLM	SFMP
TTFT ↓	ms	17.47	22.51	**19.67**	21.99	23.07	27.48	86.99
TPOT ↓	ms/token	17.19	21.12	**7.54**	20.77	21.78	24.05	82.33
Throughput ↑	tok/s	58.18	47.33	**132.28**	48.13	45.91	41.58	12.15
Resident GPU Mem. ↓	GiB	5.99	2.08	2.72	**2.11**	2.12	2.87	2.15
Peak VRAM ↓	GiB	6.09	2.16	2.72	**2.20**	2.21	2.92	2.37
Energy ↓	J/1K tokens	2280.68	2322.34	**1267.92**	2047.43	1732.24	2172.71	22535.65

主表吞吐 132.28 vs 58.18 tok/s （ BF16 ） ， 约 2.27× 。
常驻内存 2.72 vs 5.99 GiB ； 均为 GPU 条件，非昇腾结果。

洞察启示 昇腾先核对算子支持、合法 shape 与数据布局，再比较同质量、同总字节预算的统一位宽和混合 tile 。穿刺验证需计入重排、解码与临时缓冲；只有端到端 TTFT/TPOT 净改善才推进。

Activation Sparsity with Weight Approximation for Faster LLM Decoding on Offloaded Weights （激活 × 剪枝；关联权重 × 量化）

参考： arXiv:2610.02598 v1 · Fig.2 / Fig.6 · Fig.6 (CPU panels) excerpt

技术背景 LG 与多伦多大学团队针对权重卸载时每个解码 token 都要搬运大量数据，把读取决策分成原权重、压缩近似和跳过三档。小激活降低近似误差，大激活保留质量；研究价值主要在外部传输受限负载。

技术细节

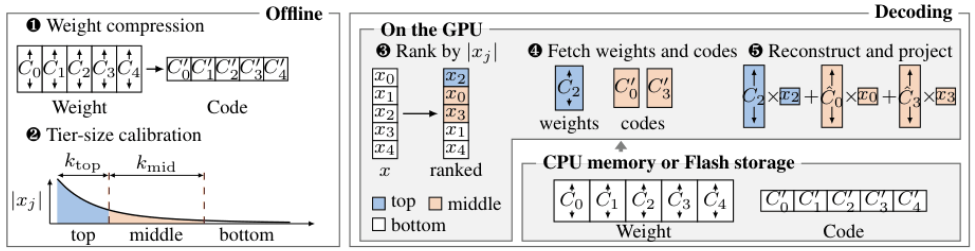
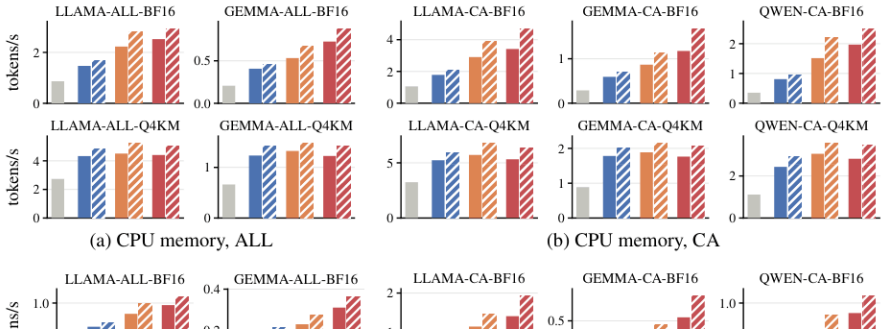


Figure 2: Overview of SpAx. Offline encoding and calibration prepare compressed weight codes and determine tier sizes. During decoding, activation magnitudes determine which columns to read in the original format, reconstruct from compressed codes, or skip.

三档读取： 按激活大小读取完整、近似或零权重。
离线编码： 标量量化或 trellis 编码保存中间档。
传输协同： 根据 CPU 或闪存布局取码并重建投影。

实验结果

模型： Llama 、 Gemma 、 Qwen ，多种卸载配置。
负载： 权重卸载 CPU 内存或闪存，逐 token 解码。
质量门槛： WikiText-2 PPL 增幅≤ 10%； 对比稠密与 TEAL 。



CPU 卸载 16-bit/4-bit 权重，平均加速 3.86×/2.06× 。
闪存卸载平均 3.31×/1.54×； 不是常驻 HBM 加速。

洞察启示 条件研究：只有权重卸载且传输主导时优先。昇腾先测链路字节与搬运时间，再验证三档访问；常驻 HBM 场景需单独评估索引、解码与不规则算子开销，不能直接套用论文倍数。

Tailoring the Quantization Space for 1-Bit KV Cache Compression （KV Cache × 量化）

参考： arXiv:2610.03027 v1 · Fig.2 / Fig.4 · 2026-10-02

技术背景 首尔大学与斯坦福大学团队针对 1-bit KV 向量量化的质量下降，在 RoPE 前按查询敏感性与通道相关性改造 Key 空间。技术目标是扩大长生成可容纳的 batch，同时控制注意力误差和推理失稳。

技术细节

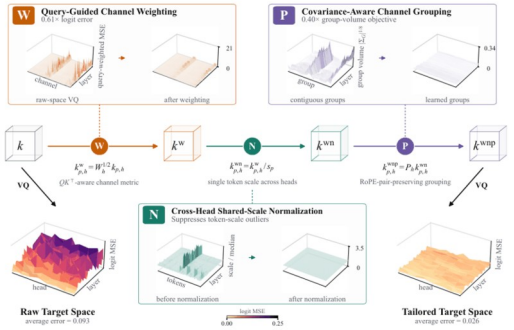


Figure 2: Overview of TaSQ. It tailors the VQ target space through query-guided channel weighting, cross-head shared-scale normalization, and covariance-aware grouping that preserves RoPE pairs, thereby reducing quantization error.

查询加权： Key 误差按 QK 敏感性优化，保护重要通道。
跨头归一化： 同 token 共用尺度，降低尺度存储开销。
相关分组： 保持 RoPE 对，拟合码本； Value 采用常规 VQ 。

实验结果

平台： 单 RTX 6000 Ada， SGLang 服务栈。
负载： Qwen3-4B-Thinking-2507， 2048 输入 /32768 输出。
对照： BF16 与 CQ；另测 8K/16K/32K 的 batch-1 prefill 。

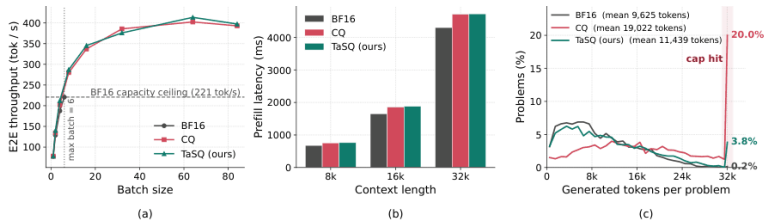


Figure 4: Serving efficiency of Qwen3-4B-Thinking-2507 model measured on one RTX 6000 Ada GPU. **(a)** End-to-end throughput vs. batch size (2048 in / 32768 out); dashed line = BF16 peak, dotted line = BF16's largest feasible batch. **(b)** Batch-1 prefill latency at 8k/16k/32k. **(c)** Generated tokens per problem on LiveCodeBench-v6, with the 32k cap shaded and the cap-hit rate per method.

最大 batch 6→84，峰值吞吐 220.8→412.6 tok/s （1.87× ）。
8K–32K 输入 TTFT 增加 10%–14%；需与长输出收益一起看。

洞察启示 昇腾先建立受支持 KV 量化基线，再用 8K/16K/32K 输入与短、长输出做对照。穿刺分开看同 batch 延迟和同 HBM 容量吞吐，计入码本、查表与编码成本；短输出不宜套用峰值收益。

Page-EntroKV: Hardware-Aligned, Entropy-Weighted KV-Cache Eviction under Grouped-Query Attention （KV Cache × KV Cache 淘汰）

参考： arXiv:2610.03135 v1 · Fig.1 / Fig.4 · 2026-10-02

技术背景 SRM 团队针对 GQA 逐头保留集合取并集后超预算，用去除 sink 影响的熵给组内头加权，再映射到物理页淘汰。该方案把保留决策与真实分配单元对应，避免只统计逻辑 token 而低估缓存占用。

技术细节

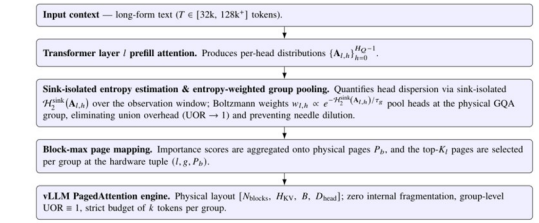
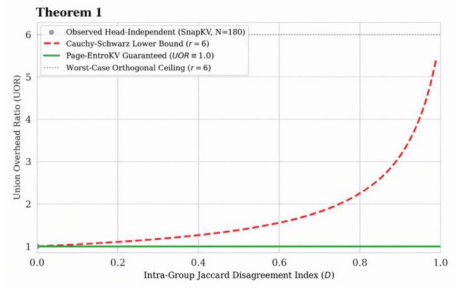


Figure 1: Page-EntroKV pipeline overview. Sink-isolated entropy-weighted pooling at the physical GQA group level, followed by block-max mapping onto PagedAttention page frames, aligns the eviction decision with the engine's physical memory layout.

物理组预算： 在共享 KV 组决策，避免逐头集合并集膨胀。
熵加权聚合： 分离 sink ， 突出尖锐检索头的重要信号。
页粒度淘汰： 先映射分配页，再严格按预算选择保留页。

实验结果

模型： Qwen2.5-1.5B-Instruct ， GQA ratio=6 。
证据： 真实文本回放，非完整生产服务吞吐试验。
图 4 ： 逐头选择的实测 UOR ， 理论包络与组级预算保证。



mpirical union overhead ratio versus intra-group Jaccard disagreement (r=6, Qwen2.5-1.5B pilot, Section 6.2). Blue: observed hea SnapKV-style replay). Red dashed: the Cauchy–Schwarz lower envelope of Theorem 1. Green: Page-EntroKV's pooled selection, (Theorem 3). Dotted: the worst-case orthogonal ceiling r. The observed tail approaches the envelope at high disagreement.

作者逐头回放： 2% 预算时 UOR 最高 4.75 ； 40% 时 2.33 。
组 / 页选择 UOR=1 ； 192 个算子 / 页大小单元精确兑现配额。

洞察启示 昇腾先验证现有分页管理中的逻辑 token 、物理页与 HBM 字节是否一致。对照完整 KV 和简单预算策略，计入评分、搬移与索引开销。长上下文质量和服务时延需独立实测后再决定工程化。

AttSVD: Prompt-Adaptive Low-Rank KV Cache Compression via Attention-Guided SVD （KV Cache × 低秩分解）

参考： arXiv:2610.06927 v1 · Fig.1 / Table 1 excerpt

技术背景 微软 ASG 团队针对删 token 后无法恢复上下文，沿特征轴而非序列轴压缩 KV 。每个提示按注意力几何生成低秩基，保留所有位置；短输出采用累积缓存，长输出用流式窗口控制增长，但分解和重构成本需独立核对。

技术细节

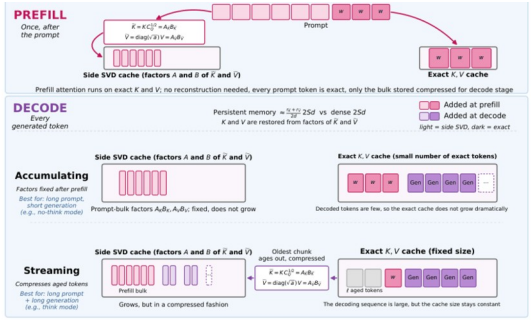


Figure 1: AttSVD keeps a thin, compressed side cache of attention-aware factors A, B plus a small exact cache of recent tokens, cutting persistent memory to a fraction of dense while retaining all token positions. At decode, *accumulating* keeps every token exact (small decoded tokens); *streaming* compresses tokens leaving a sliding window, keeping the exact buffer bounded.

注意力感知：分别保留 logit 与输出空间中的有效方向。
逐提示 SVD：按能量阈值选择 K/V 秩，而非固定离线基。
双解码策略：累积精确 token 或按窗口重分解。

实验结果

模型： Phi-4-14B 、 Qwen3-8B 等。
任务： 1750 项 LongBench 与 184 项 agent 提示。
比较： Dense 、 H2O 、 KVzip 、 KeyDiff ，匹配缓存预算。

	Rank r	KV @32K (GiB)	Measured ratio	KV @9.4K (GiB)	KV @32K (GiB)	Measured ratio	KV @9.4K (GiB)
Dense cache	128	6.250	1.000	1.804	4.500	1.000	1.299
AttSVD (c=0.50)	64	3.139	0.502	0.916	2.260	0.502	0.660
AttSVD (c=0.75)	32	1.571	0.251	0.459	1.131	0.251	0.330
AttSVD (c=0.875)	16	0.787	0.126	0.231	0.567	0.126	0.166

Phi-4-14B 32K： KV 6.250→3.131 GB （c=0.50 ）。
50% 缓存 LongBench 接近稠密表现；未证明统一服务加速。

洞察启示 持续跟踪：优先检查真实业务提示的注意力有效秩。昇腾穿刺分解、重构和窗口刷新成本，再与同字节预算 KV 量化或淘汰对比；只有长上下文收益摊薄分解开销才值得接入。

昇腾研究判断：按技术地图确定投入顺序

权重 × 量化：优先穿刺规则精度布局与合法算子粒度； StagQ 、 DBW 及补偿方案只在极低总字节或多档部署约束下推进。
激活 × 剪枝： SpAx 优先针对卸载搬运； HBM 常驻模型必须另测动态选择、索引和不规则执行成本。
KV Cache × 量化： TaSQ 先核对质量、 TTFT 和容量收益，区分同 batch 时延与同 HBM 下吞吐。
KV Cache × 淘汰： Page-EntroKV 先核对物理页释放； DeferKV 补充淘汰时机，组合收益尚无证据。
KV Cache × 低秩 / GQA-MQA： AttSVD 与 SAGA 持续跟踪，分解刷新或训练改造成本须进入预算。

穿刺建议：固定模型、质量门槛与 SLA ；分别测驻留字节、 TTFT 、 TPOT 、同容量吞吐及准备成本。 GPU 论文结果不是昇腾预期收益。

â…¬à¼€è®ºæ–‡ Â· ç ”ç©¶â»è®®

附录：同路线补充工作，按需展开而非堆入正文

权重 × 量化： StagQ 补充多档共享码流；有多精度部署需求再评估。
权重 × 剪枝 / 量化 / 低秩： DBW 补充分量预算联合优化，适合亚 2-bit 容量压力。
权重 × 量化 / 低秩： Align, Then Correct 补充质量恢复，但需计入统计和适配器成本。
KV Cache × 淘汰： DeferKV 补充首步真实查询决定淘汰时机。
KV Cache × GQA-MQA： SAGA 补充头结构改变，需训练 / 微调与算子改造。

TopK-Guided 、 OSFP4 、 Behavior-Preserving 仍保留在网页分析；原 PDF 无适合该模板的系统设计总览图，不用装饰图补位。

â…¬à¼€è®ºæ–‡ Â· ç "ç©¶à»ºè®®
HUAWEI

StagQ: Constraint-Driven Multi-Precision Weight Quantization for LLMs （权重 × 量化）

参考： arXiv:2610.05977 v1 · Fig.3 / Table 1 · Table 1 (2-bit rows) excerpt

技术背景 华为团队针对同一模型多精度部署需要存多份权重，采用共享前缀流与稀疏旁路补偿。研究价值是用一份编码提供多个精度档位，同时把异常值和元数据纳入实际码率；规则解码仍需专用内核。

技术细节

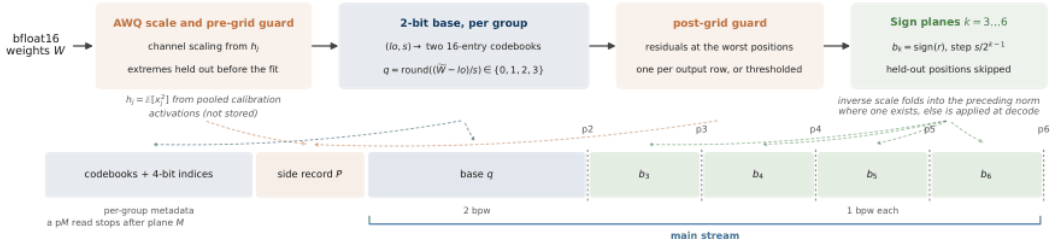


Figure 3: The StagQ encoder and the fields its rate charges. Dashed lines in each stage's color map the stage to the field it fills. A pM read stops after plane M.

共享前缀： 2-bit 基础流叠加 1-bit 细化平面。
共享元数据： 各精度用同一仿射映射解码。
异常值旁路： 编码前后保留难量化权重，计入总码率。

实验结果

模型： Llama-3.1-8B 、 Phi-4 、 OLMo-2-7B 。
质量： MMLU 、常识任务及 WikiText-2 。
执行： A100 、 batch-1 、合成权重 GEMV ； 不是服务吞吐。

Method	Bit	Rate	MMLU	ARC-C	ARC-E	HS	PIQA	WG	CSR Avg
bfloat16	16	16.00	65.23	53.67	81.06	78.91	81.28	73.72	73.73
MatGPTQ	2	2.25	24.65	24.74	24.45	26.29	51.41	49.17	35.21
Any-Precision	2	2.01	23.82	24.57	34.09	27.90	57.24	50.36	38.83
AnyBCQ	2	2.38	35.33	37.29	62.67	62.76	73.94	57.93	58.92
StagQ-XXS	2	2.35	38.38	38.05	60.94	63.63	73.23	65.27	60.23
StagQ-XS	2	2.64	**48.67**	**41.98**	**70.12**	**70.05**	**75.52**	**67.32**	**65.00**

2-bit 较最强多精度基线提高 MMLU 3.1–7.0 个百分点。
4-bit 质量持平但码率更高，不能只比较名义位宽。

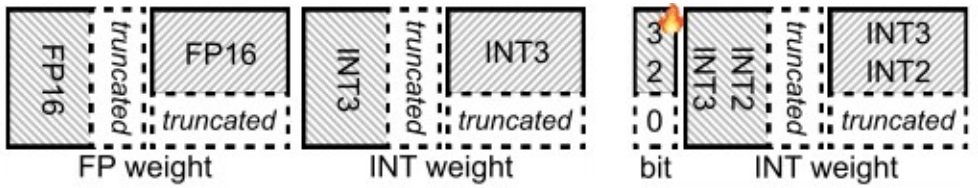
洞察启示 条件研究：适合确有多档部署需求的模型。昇腾先比较总驻留字节与档位切换成本，再对旁路布局和 GEMV 做穿刺；单一位宽业务不应为共享流承担额外复杂度。

DBW：联合优化分量剪枝与量化（权重 × 量化 / 剪枝 / 低秩分解）

参考： arXiv:2610.06026 v1 · Fig.1 / Table 1 · Table 1 (LLaMA-7B) excerpt

技术背景 亚洲大学团队针对先截断 SVD 、再量化的两阶段误差，联合学习分量位宽。 0-bit 表示删除分量，其余分量分配不同位宽。该方案争取极低存储预算下的质量，但校准训练与混合位宽执行需要额外成本。

技术细节



(a) **Sequential** optimization (b) **Co**-optimization

Figure 1: **Our compression concept illustration.** We co-optimize pruning and quantization in a single step by updating bit-widths in our differentiable method.

联合目标： 同时决定截断秩和保留分量位宽。
可微位宽： 0-bit 分量删除，预算在分量之间重新分配。
规则打包： 按位宽分组执行，避免逐分量不规则访存。

实验结果

模型： LLaMA 系列 7B–70B 及非 LLaMA 对照。
设置： 平均 1.61-bit 、 group size 128 。
基线： PTQ 、 BiLLM 及两阶段 SVD 压缩； 8 项常识任务。

LLaMA	Method	Group	Bits	PIQA	ARC-e	HellaS	Wing	Race	ARC-c	LAMB-o	LAMB-s	Avg.
1-7B	FP16	-	16	78.67	75.29	56.99	70.01	40.29	41.81	73.57	67.82	63.06
	GPTQ	128	2	59.41	36.11	32.59	50.43	27.56	20.31	12.79	9.02	31.03
	SliM-LLM+	128	2	65.72	52.74	39.49	55.33	34.35	23.81	38.15	22.96	41.57
	OmniQuant	128	2	67.74	59.51	41.24	56.75	33.30	28.41	40.89	25.75	44.20
	PB-LLM	128	1.7(+1)	55.71	29.12	28.31	48.86	26.41	19.80	10.42	10.09	28.59
	BiLLM	128	1(+1.1)	61.10	40.99	31.80	53.67	30.14	20.64	23.15	16.48	36.00
	PTQ1.61	-	1.61	63.71	49.62	35.73	56.75	32.54	25.26	38.93	26.57	41.14
	DBW(Ours)	128	1.61	69.53	57.24	41.39	60.38	35.79	28.58	53.74	45.20	48.98

LLaMA-7B 常识均分 48.98% ， 两阶段 PTQ 为 41.14% 。
该 1.61-bit 质量结果不能替代昇腾端到端执行测试。

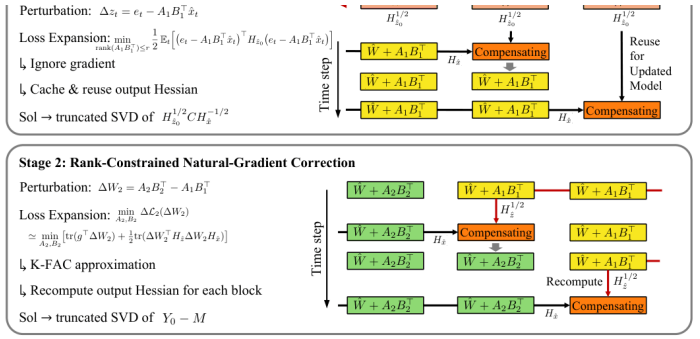
洞察启示 条件研究：业务需要亚 2-bit 权重时再评估。固定总字节预算比较质量，并计入低秩因子、尺度、重训和多个 GEMM 成本；先核对昇腾可执行的位宽集合，再做算法适配。

Align, Then Correct： 免训练的两阶段低秩补偿（权重 × 量化 / 低秩分解）

参考： arXiv:2610.08164 v1 · Fig.3 / Table 1

技术背景 汉阳大学与 Qualcomm 团队针对低秩补偿目标难以低秩拟合、只优化二阶误差的问题，先做 Fisher 加权非对称对齐，再校正剩余一阶误差。权重保持冻结，闭式求适配器；免训练不等于免校准。

技术细节



gure 3: The proposed two-stage procedure on a three-block model. Every linear layer keeps its quantized weight $\hat{W}$ fro d attaches a rank-r adapter $AB^\top$. **(a)** Stage 1 sweeps the decoder front to back. The output Fisher $H_{\hat{z}_0}$ is computed once ısed, whereas the input moments $H_{\hat{x}}$ and $\tilde{H}_x$ are refreshed before each block. **(b)** Stage 2 repeats the sweep, collecting g, d $H_{\hat{z}}$ with one forward and backward pass per block before applying the natural-gradient correction. Red outlines indic

输出对齐：用全精度与量化模型的不同输入构造目标。
统计重测：第一阶段补偿后重新采集梯度与曲率。
低秩校正：限秩自然梯度方向由截断 SVD 求解。

实验结果

模型： Qwen3-8B/4B， 主实验 QuIP# 2-bit 。
校准： 128×2048 WikiText-2， rank 64 等设置。
质量： WikiText-2/C4 PPL， 7 项零样本任务。

FP16	9.73	15.24	69.38	13.64	19.84	66.73
QuIP#	12.43	19.19	62.81	21.11	29.21	57.47
+ EoRA	12.20	18.98	63.03	20.92	27.71	58.69
+ QERA	12.22	18.97	63.06	20.91	27.67	58.63
+ ProjQ	12.15	18.91	63.07	21.16	27.81	58.41
+ LQ-LoRA	11.62	17.95	64.29	16.75	23.34	59.66
+ Ours	**10.26**	**17.17**	**64.51**	**13.22**	**21.36**	**60.05**

Table 1: Main results at 2 bits: WikiText-2 and C4 perplexity (↓) and the CSQA Avg, the mean of the seven zero-shot common-sense QA accuracies (↑), under QuIP# quantization. Calibration uses WikiText-2 only, so C4 is held out. Best per model in **bold**; the FP16 row is a reference and is excluded. Qwen3 uses a different tokenizer, so its perplexity should be read against its own family. Per-model tables covering all three bit-widths and the per-task breakdowns are given in Appendix I.

Qwen3-8B WikiText-2 PPL： 12.43→10.26 。
Qwen3-4B PPL： 21.11→13.22； 还需计入适配器字节。

洞察启示 条件研究：对极低比特质量不足的模型，先比较同总容量下更高位宽与低秩补偿。昇腾穿刺需计入适配器 GEMM 、统计校准和并行通信；质量恢复成立之后再判断时延净收益。

DeferKV: Rethinking Eviction Timing for One-Shot KV Cache Compression （KV Cache × KV Cache 淘汰）

参考： arXiv:2610.06286 v1 · Fig.3 / Table 1 · Table 1 (Qwen3-8B) excerpt

技术背景

电子科技大学团队针对 prefill 末尾查询不能代表后续生成，把不可逆淘汰推迟到首个真实 decode 查询。结合提示与生成侧注意力再选 KV ，不增加草稿模型或训练；其价值是改善淘汰时机而非改变压缩格式。

技术细节

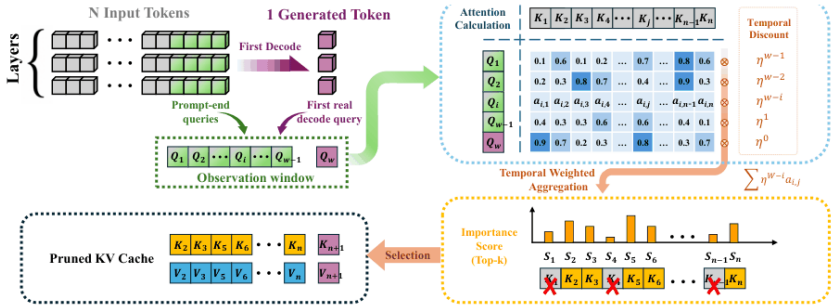


Figure 3: Overview of DeferKV. The first real decode query is combined with recent prompt queries and temporally weighted to estimate KV importance for subsequent cache compression.

真实查询： 首次 decode 时获取真实生成需求。
时间加权： 近期 prompt 查询和 decode 查询联合打分。
一次淘汰： 保留原方法预算结构，更换重要性估计。

实验结果

模型： Qwen3-8B 、 Llama-3.1-8B 、 Mistral-7B 。
评测： 16 项 LongBench 、 RULER 和针检索。
比较： SnapKV 、 LAQ 、 SpecKV 、 LookaheadKV 及 Full KV 。

Method	Single-Doc QA			Multi-Doc QA			Summ.			Few-Shot			Synth.		Code		Avg.
	NrtvQA	Qasper	MF-en	HotpotQA	2WikiMQA	MuSiQue	GovReport	QMSum	MultiNews	TREC	TriviaQA	SAMSum	PCount	PR-en	LCC	RB-P	
Qwen3-8B, $B_{\text{total}} = 64L$																	
SnapKV	17.41	30.06	38.05	47.77	37.71	20.65	14.00	19.37	12.93	43.50	81.92	36.53	5.00	87.50	59.30	53.58	37.83
LAQ	18.99	**37.88**	43.31	53.88	41.35	23.24	**16.18**	19.40	14.78	66.00	88.40	**37.64**	5.50	94.50	62.31	55.91	42.45
SpecKV	19.61	29.97	**49.79**	51.03	36.97	22.14	13.27	**19.72**	**14.82**	37.50	73.63	36.71	6.00	95.00	45.15	46.62	37.37
LookaheadKV	18.22	32.27	40.12	47.66	38.01	23.58	14.61	18.36	13.18	46.95	83.29	36.69	5.00	90.40	59.06	54.28	38.86
DeferKV	**21.87**	35.37	45.97	**56.99**	**41.88**	**31.20**	14.81	19.52	13.52	**70.50**	**89.98**	37.44	**8.00**	**97.50**	**62.52**	**56.47**	**43.97**
Qwen3-8B, $B_{\text{total}} = 512L$																	
SnapKV	22.70	42.96	51.19	57.09	42.51	**34.94**	25.14	**23.44**	21.87	68.50	89.46	43.34	**9.50**	**100.00**	**68.74**	64.22	47.85
LAQ	23.16	43.58	52.63	56.16	43.02	34.36	25.46	22.02	21.94	71.00	**90.05**	43.35	**9.50**	**100.00**	67.92	64.72	48.05
SpecKV	24.38	43.27	**53.93**	58.07	42.90	31.48	**29.51**	23.24	**24.05**	71.00	89.96	29.60	4.00	99.00	56.84	56.85	46.13
LookaheadKV	23.10	43.67	52.21	56.86	43.12	34.91	25.46	22.71	22.08	71.00	89.97	**43.85**	**9.50**	99.00	68.01	**64.98**	48.15
DeferKV	**24.82**	**44.78**	51.96	**58.09**	**43.18**	33.83	26.04	22.74	22.17	**71.50**	**90.05**	43.70	**9.50**	**100.00**	67.55	64.02	**48.37**
Full KV	24.73	48.05	54.39	58.16	43.79	34.27	33.45	24.12	24.84	71.50	90.21	44.56	9.50	100.00	69.34	65.48	49.77

Qwen3-8B 、 KV 预算 512 ： LongBench 均分 44.96 ， SnapKV 38.46 。RULER 跨 4K–128K 均分 81.36 ， Full KV 93.46 ；并非无损。

洞察启示

条件研究：长提示、短输出业务先比较同保留预算的质量和 TTFT 。昇腾核对首步延迟淘汰是否增加峰值 HBM ，并计入注意力取样、评分与页搬移；它可与页预算策略组合，但组合收益要另测。

More Value per Key: Asymmetric Sparse Attention for Faster LLM Decoding （KV Cache × GQA / MQA）

参考： arXiv:2610.04753 v1 · Fig.1 / Fig.2 · v1

技术背景

Technion 等团队针对稀疏注意力后 QK 计算仍是瓶颈，减少 Key 头而保留更多 Value 头，再用近似 top-N 选择。技术价值是改变 K/V 结构以匹配瓶颈，但需训练或微调转换，不能作为普通模型的无损缓存插件。

技术细节

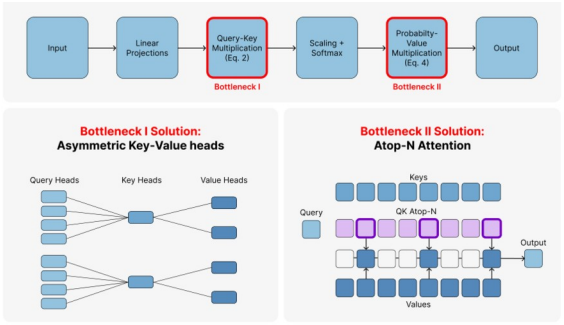


Figure 1: Diagram of SAGA. There are two significant decoding bottlenecks in attention mechanisms: key-query multiplications and probability-value multiplications (top). SAGA addresses the query-key bottleneck by reducing the number of key heads (left). The probability-value bottleneck is mitigated by utilizing Atop-N to select important values (right).

非对称 K/V： 少量 Key 头减少 QK 访存与计算。
近似 top-N： 控制参与 PV 的候选，保留 Value 表达能力。
模型转换： 蒸馏或微调适配新头结构，需要质量重验。

实验结果

模型： Llama-3.2-1B 、 Qwen2.5-1.5B 。
平台： H200/B200； batch 1/4/16 、上下文 8K–128K 。
比较： 作者同栈完整注意力 GQA， CUDA Graph 解码。

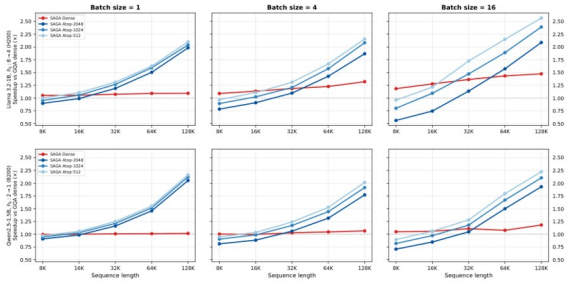


Figure 2: End-to-End speedup over baseline full attention as a function of sequence length, for Llama 3.2-1B ($h_k : 8 \rightarrow 4$, H200) and Qwen2.5-1.5B ($h_k : 2 \rightarrow 1$, B200) at various batch sizes. Merging alone (SAGA full) gives a consistent speedup across all configurations. Combining merging

作者长上下文端到端解码加速超过 2×， 模型最大 1.5B 。
从头训练质量接近 GQA； 不能外推现有大模型免训练收益。

洞察启示

持续跟踪：适合有模型结构改造权限的研究线。昇腾先验证非对称头布局与算子支持，再比较同训练预算质量、同栈解码与转换成本；现有生产模型优先选择保持模型结构的 KV 压缩。

Thank you.

把数字世界带入每个人、每个家庭、
每个组织，构建万物互联的智能世界。

Bring digital to every person, home, and organization for a fully connected, intelligent world.

Copyright©2021 Huawei Technologies Co., Ltd.
All Rights Reserved.

The information in this document may contain predictive statements including, without limitation, statements regarding the future financial and operating results, future product portfolio, new technology, etc. There are a number of factors that could cause actual results and developments to differ materially from those expressed or implied in the predictive statements. Therefore, such information is provided for reference purpose only and constitutes neither an offer nor an acceptance. Huawei may change the information at any time without notice.

HUAWEI