2026 年 10 月推理压缩洞察
从需求、实现到昇腾研究决策



部门：云核 · 推理压缩
日期： 2026-10-09

HUAWEI

本期阅读路径：先看技术方案，再看需求和实现条件

正文顺序： 01 学术进展 → 02 热点资讯 → 03 产业动态 → 04 综合判断；补充论文在附录

01 学术进展

技术地图组织研究方案

5 篇正文代表论文 + 5 篇图文附录；按权重、激活、 KV Cache 识别压缩对象与方法。

看清方案、原图和实验条件，再选择具体论文穿刺。

02 热点资讯

事件解释需求如何改变

3 个独立事件： MoE 参数预算、低比特真实成本、任务专用小模型。

回答为什么值得研究，不把热点当作昇腾性能证据。

03 产业动态

版本与算子限定落地路径

4 页： msModelSlim 、量化 Attention 、 vLLM-Ascend 候选适配与稳定版修复。

回答哪里已有实现、哪里仍受格式、硬件和版本限制。

综合判断：论文决定研究方案；热点解释需求；产业版本决定可执行边界。

截止 2026-10-09； 10 月尚未结束。公开范围内未确认新的十月昇腾正式发布，不补造事件；未进行昇腾实测。

大类	技术名称	技术简介
权重	**AlignQuant**	权重 × 量化：二维 tile 统一混合精度、紧凑存储与 prefill/decode 执行。
激活	**SpAx**	激活 × 剪枝；关联权重 × 量化：小激活读取压缩权重，大激活读取原权重，近零激活跳过。
KV Cache	**TaSQ**	KV Cache × 量化：在 RoPE 前对 Key 加权、跨头归一化和相关通道分组，再向量量化。
KV Cache	**Page-EntroKV**	KV Cache × KV Cache 淘汰：按 GQA 共享组聚合重要性，映射页后淘汰，严格控制实际保留预算。
KV Cache	**AttSVD**	KV Cache × 低秩分解：提供累积与流式两种解码缓存策略。

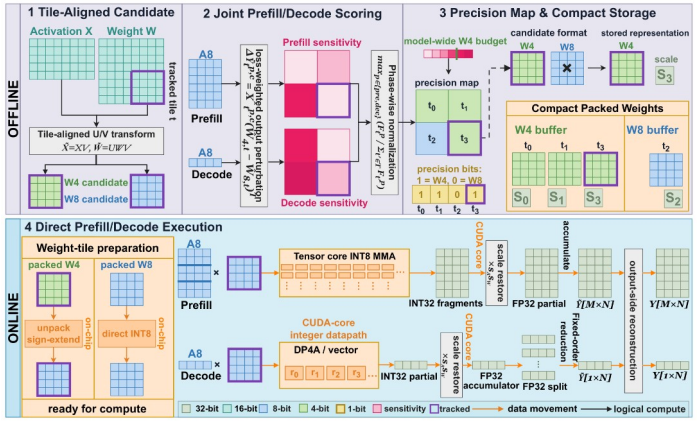
HUAWEI

AlignQuant （权重 × 量化）

AlignQuant: Tile-Aligned Mixed-Precision Quantization for Efficient LLM Generation

北德克萨斯大学与圣路易斯大学团队针对混合精度边界和 GPU 执行单元错位，采用二维权重 tile 统一校准、打包与计算。研究价值是把模型变小与生成变快接起来，降低异构位宽的执行开销。

技术方案 • 论文原图



共同粒度： 64×64 tile 选择 W4/W8 ， 使用 A8 输入。

联合校准：综合 prefill/decode 敏感性，在全模型预算内分配位宽。

直接执行： W4 紧凑加载后展开为 INT8 ， 阶段专用核复用同一模型。

实验结果 • 原始条件

平台： A100-SXM4 40GB ；扩展至 H100 NVL 、 RTX 4090 。

模型：主结果 Llama-3.2-3B ， 64×64 tile 、 60% W4 。

基线： BF16 及 GPTQ/AWQ 等；单次完整生成的 TTFT 、 TPOT 与容量。

Metric	Unit	Upper Ref.	Lower Ref.	Ours	Others			
		BF16	W4A8	*AlignQuant*	GPTQ	AWQ	MixLLM	SFMP
TTFT ↓	ms	17.47	22.51	**19.67**	21.99	23.07	27.48	86.99
TPOT ↓	ms/token	17.19	21.12	**7.54**	20.77	21.78	24.05	82.33
Throughput ↑	tok/s	58.18	47.33	**132.28**	48.13	45.91	41.58	12.15
Resident GPU Mem. ↓	GiB	5.99	2.08	2.72	**2.11**	2.12	2.87	2.15
Peak VRAM ↓	GiB	6.09	2.16	2.72	**2.20**	2.21	2.92	2.37
Energy ↓	J/1K tokens	2280.68	2322.34	**1267.92**	2047.43	1732.24	2172.71	22535.65

主表吞吐 132.28 vs 58.18 tok/s （ BF16 ） ， 约 2.27× 。

常驻内存 2.72 vs 5.99 GiB ； 均为 GPU 条件，非昇腾结果。

昇腾建议

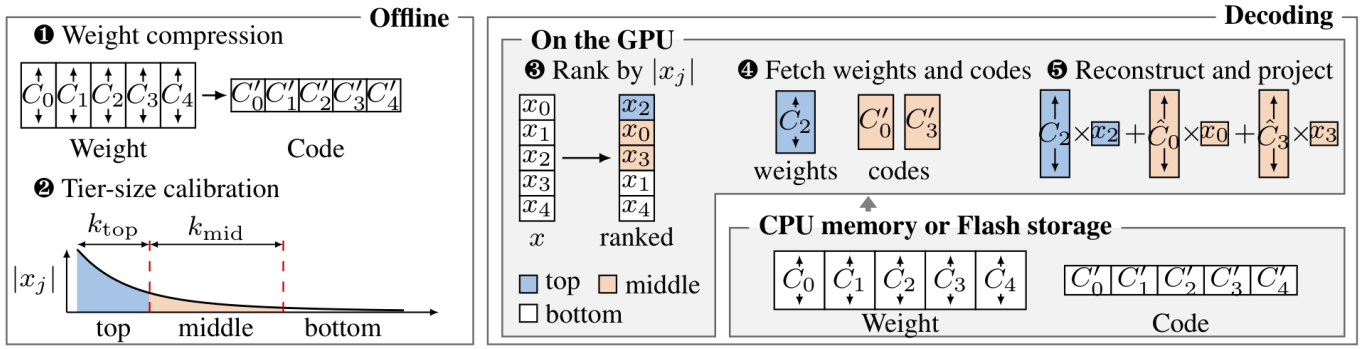
昇腾先核对算子支持、合法 shape 与数据布局，再比较同质量、同总字节预算的统一位宽和混合 tile 。穿刺验证需计入重排、解码与临时缓冲；只有端到端 TTFT/TPOT 净改善才推进。

SpAx （激活 × 剪枝；关联权重 × 量化）

Activation Sparsity with Weight Approximation for Faster LLM Decoding on Offloaded Weights

LG 与多伦多大学团队针对权重卸载时每个解码 token 都要搬运大量数据，把读取决策分成原权重、压缩近似和跳过三档。小激活降低近似误差，大激活保留质量；研究价值主要在外部传输受限负载。

技术方案 • 论文原图



三档读取：按激活大小读取完整、近似或零权重。

离线编码：标量量化或 trellis 编码保存中间档。

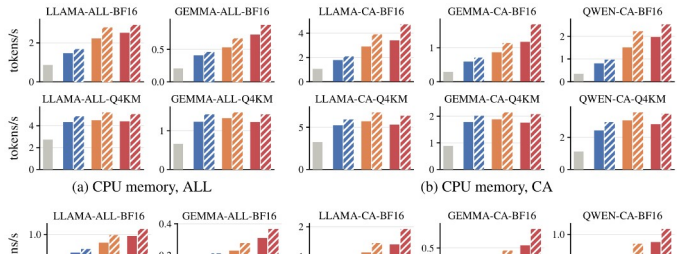
传输协同：根据 CPU 或闪存布局取码并重建投影。

实验结果 • 原始条件

模型： Llama 、 Gemma 、 Qwen ，多种卸载配置。

负载：权重卸载 CPU 内存或闪存，逐 token 解码。

质量门槛： WikiText-2 PPL 增幅≤ 10%； 对比稠密与 TEAL 。



CPU 卸载 16-bit/4-bit 权重，平均加速 3.86×/2.06× 。

闪存卸载平均 3.31×/1.54×； 不是常驻 HBM 加速。

昇腾建议

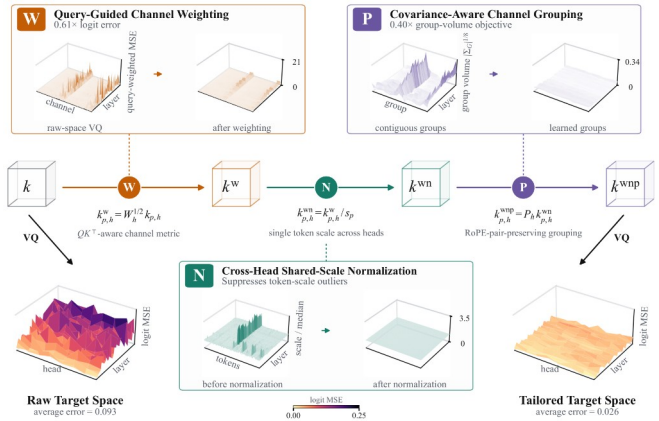
条件研究：只有权重卸载且传输主导时优先。昇腾先测链路字节与搬运时间，再验证三档访问；常驻 HBM 场景需单独评估索引、解码与不规则算子开销，不能直接套用论文倍数。

TaSQ （KV Cache × 量化）

Tailoring the Quantization Space for 1-Bit KV Cache Compression

首尔大学与斯坦福大学团队针对 1-bit KV 向量量化的质量下降，在 RoPE 前按查询敏感性与通道相关性改造 Key 空间。技术目标是扩大长生成可容纳的 batch，同时控制注意力误差和推理失稳。

技术方案 • 论文原图



查询加权： Key 误差按 QK 敏感性优化，保护重要通道。

跨头归一化：同 token 共用尺度，降低尺度存储开销。

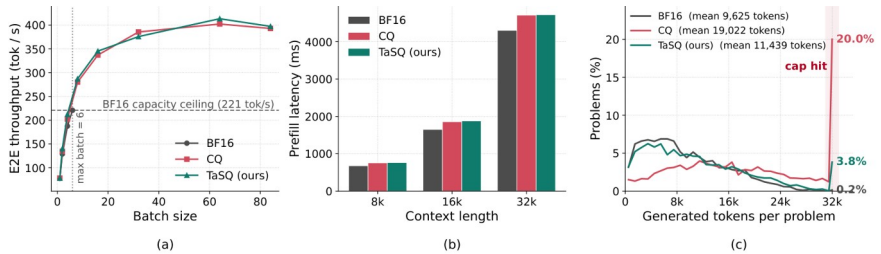
相关分组：保持 RoPE 对，拟合码本； Value 采用常规 VQ 。

实验结果 • 原始条件

平台：单 RTX 6000 Ada， SGLang 服务栈。

负载： Qwen3-4B-Thinking-2507， 2048 输入 /32768 输出。

对照： BF16 与 CQ；另测 8K/16K/32K 的 batch-1 prefill 。



最大 batch 6→84，峰值吞吐 220.8→412.6 tok/s （1.87× ）。

8K–32K 输入 TTFT 增加 10%–14%；需与长输出收益一起看。

昇腾建议

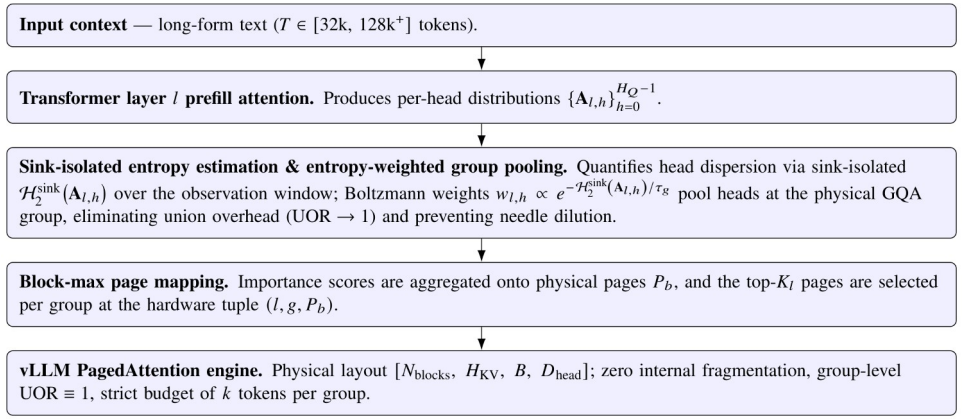
昇腾先建立受支持 KV 量化基线，再用 8K/16K/32K 输入与短、长输出做对照。穿刺分开看同 batch 延迟和同 HBM 容量吞吐，计入码本、查表与编码成本；短输出不宜套用峰值收益。

Page-EntroKV （KV Cache × KV Cache 淘汰）

Page-EntroKV: Hardware-Aligned, Entropy-Weighted KV-Cache Eviction under Grouped-Query Attention

SRM 团队针对 GQA 逐头保留集合取并集后超预算，用去除 sink 影响的熵给组内头加权，再映射到物理页淘汰。该方案把保留决策与真实分配单元对应，避免只统计逻辑 token 而低估缓存占用。

技术方案 • 论文原图



物理组预算：在共享 KV 组决策，避免逐头集合并集膨胀。

熵加权聚合：分离 sink ，突出尖锐检索头的重要信号。

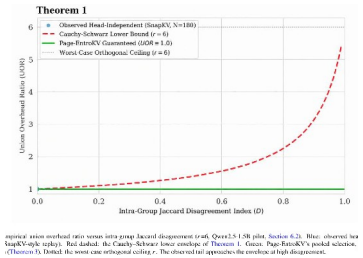
页粒度淘汰：先映射分配页，再严格按预算选择保留页。

实验结果 • 原始条件

模型： Qwen2.5-1.5B-Instruct ， GQA ratio=6 。

证据：真实文本回放，非完整生产服务吞吐试验。

图 4 ： 逐头选择的实测 UOR ， 理论包络与组级预算保证。



作者逐头回放： 2% 预算时 UOR 最高 4.75 ； 40% 时 2.33 。

组 / 页选择 UOR=1 ； 192 个算子 / 页大小单元精确兑现配额。

昇腾建议

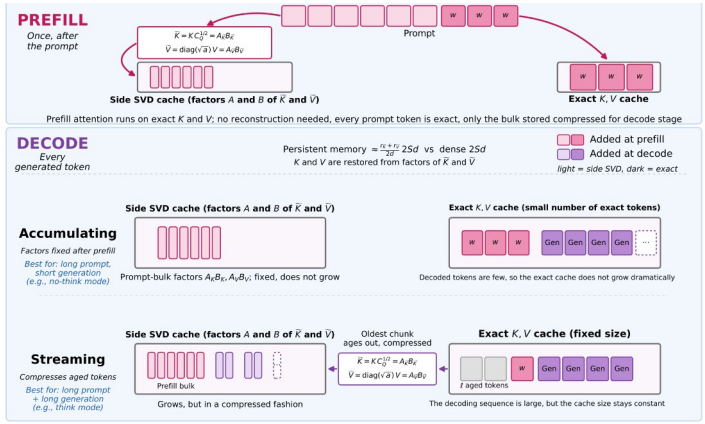
昇腾先验证现有分页管理中的逻辑 token 、物理页与 HBM 字节是否一致。对照完整 KV 和简单预算策略，计入评分、搬移与索引开销。长上下文质量和服务时延需独立实测后再决定工程化。

AttSVD （KV Cache × 低秩分解）

AttSVD: Prompt-Adaptive Low-Rank KV Cache Compression via Attention-Guided SVD

微软 ASG 团队针对删 token 后无法恢复上下文，沿特征轴而非序列轴压缩 KV 。每个提示按注意力几何生成低秩基，保留所有位置；短输出采用累积缓存，长输出用流式窗口控制增长，但分解和重构成本需独立核对。

技术方案 • 论文原图



注意力感知：分别保留 logit 与输出空间中的有效方向。

逐提示 SVD ： 按能量阈值选择 K/V 秩，而非固定离线基。

双解码策略：累积精确 token 或按窗口重分解。

实验结果 • 原始条件

模型： Phi-4-14B 、 Qwen3-8B 等。

任务： 1750 项 LongBench 与 184 项 agent 提示。

比较： Dense 、 H2O 、 KVzip 、 KeyDiff ， 匹配缓存预算。

	Rank r	KV @32K (GiB)	Measured ratio	KV @9.4K (GiB)	KV @32K (GiB)	Measured ratio	KV @9.4K (GiB)
Dense cache	128	6.250	1.000	1.804	4.500	1.000	1.299
AttSVD (c=0.50)	64	3.139	0.502	0.916	2.260	0.502	0.660
AttSVD (c=0.75)	32	1.571	0.251	0.459	1.131	0.251	0.330
AttSVD (c=0.875)	16	0.787	0.126	0.231	0.567	0.126	0.166

Phi-4-14B 32K： KV 6.250→3.131 GB （c=0.50）。

50% 缓存 LongBench 接近稠密表现；未证明统一服务加速。

昇腾建议 持续跟踪：优先检查真实业务提示的注意力有效秩。昇腾穿刺分解、重构和窗口刷新成本，再与同字节预算 KV 量化或淘汰对比；只有长上下文收益摊薄分解开销才值得接入。

Mistral Large 4：万亿参数 MoE 把权重容量推到前台

2026-10-06 · Mistral 官方预览公告 · 关联技术地图：权重 × 量化

01 发生了什么 • 原始事实

01 模型规模

官方披露 1T 总参数、 52B 激活参数；两者分别描述模型规模与稀疏激活规模。

02 开放状态

预览 API 已开放；权重计划月底发布。截止核对时，不把开放计划写成已交付。

03 研究窗口

权重和架构细节尚待发布；当前不能复核专家布局、可量化层或部署格式。

02 为什么重要 • 研究分析

容量预算：总权重仍需有去处

52B 激活参数不能替代总参数容量账。需区分全量驻留、专家分层存储、每 token 搬运与通信成本。

技术选择：量化与驻留要共同设计

专家权重量化可减小存储与搬运字节，但收益取决于路由命中、解码开销和并行划分，不能只按名义位宽排名。

03 观点与建议

先列入权重 × 量化跟踪；等权重公开后，优先核对专家格式与驻留预算，再决定是否投入适配。

证据边界：厂商规格与发布计划；容量与路线取舍为分析判断。未证明压缩收益或昇腾支持。

[H1] Mistral 官方公告 · Preview / Frontier performance

openTPU： 低比特要看总字节、质量与端到端收益

2026-10-01 作者实验 · build B · Kintex-7 PCIe 板卡 · 权重 × 量化

01 发生了什么 • 原始事实

01 编码成本

4-bit 权重采用两级块尺度；计入尺度后为 4.25 bit/weight，LM head 保留 INT8。

02 可比结果

Qwen3.5-2B： INT8 / 4-bit 的 wall 解码速度为 8.00 / 12.03 tok/s。

03 测量条件

512-token prompt、 64 greedy tokens； device 与 wall 分开计， DRAM 流量由板卡计数器读取。

02 为什么重要 • 研究分析

名义压缩率不能代替实际收益

12.03 / 8.00 约为 1.50 倍（计算值）；不能按位宽减半直接宣称两倍加速。尺度、保留层和反量化都要计费。

评测口径值得迁移，硬件倍数不能迁移

在昇腾报告总权重字节、端到端时延及质量变化。作者说明量化存在 PPL 代价，模拟器逐位一致不等于全精度质量无损。

03 观点与建议

把它作为量化评测口径参考；在同模型、同负载、同质量约束下比较昇腾基线，不照搬 FPGA 加速倍数。

证据边界：项目作者自测； 10-01 为实验日。上述比值由原表计算，未进行昇腾复现。

[H2] openTPU README · Results / Method / 4-bit encoding

Strands Decider 2B： 先缩小任务职责，再压缩模型

2026-10-01 · Strands 官方开源介绍 · 相邻研究背景，非剪枝或蒸馏成果

01 发生了什么 • 原始事实

01 模型改造

以 Qwen3.5-2B 为主干，替换 LM head 为 pointer head，用 rank-16 LoRA 微调。

02 任务边界

一次前向对给定选项打分；不能生成通用文本，不适合直接替代聊天、编码和摘要模型。

03 可研究性

官方开放代码、权重、训练数据与脚本；评测关注准确率、置信度校准与决策延迟。

02 为什么重要 • 研究分析

压缩前先问：业务是否需要通用生成

分类、路由和选项决策可评估任务专用模型。改变任务职责与降低数值精度是两种取舍，收益不能混在一个压缩指标里。

研究顺序：先形成任务基线，再量化

若专用模型满足业务准确率，再评估低比特质量损失与服务成本。无法承担的复杂推理仍交给通用模型。

03 观点与建议

路由业务可单列试验：先测决策准确率、校准与 P95 延迟，再判断是否量化；不纳入剪枝 / 蒸馏已实现清单。

证据边界：官方架构与开源披露；昇腾适配和本地延迟未确认。不可用生成质量评测替代决策质量。

[H3] Strands · Model Architecture / Limitations / Performance

msModelSlim： 模型 × 量化模式开始形成明确交付项

本月核对既有文档 · 26.0.0.alpha02 为内测版，发布日期未列 · 权重 / 激活 × 量化

01 发生了什么 • 原始事实

01 具体模型与模式

alpha02 列示 Qwen3-Coder-480B W4A8 、 Qwen3.5 MoE W8A8 与 GLM-5 W4A8 。

02 接入与调优变化

版本说明新增自定义 practice 目录的 entry point ， 构建 model_adapter 插件化基础，并优化自动调优。

03 算法与版本分开

V1 算法文档列出 GPTQ 、 AWQ 、 FA3 Quant 、 KVCache Quant ； 不把目录收录当作全部模型已支持。

02 为什么重要 • 研究分析

论文比较应站在可交付基线上

权重量化研究先确认目标模型能导出何种格式，再与 GPTQ / AWQ 等已支持路径比较；相同位宽仍可能因布局而不能互换。

低精度能力落地依赖三重匹配

模型实践、量化输出、推理引擎要一致。自动调优可形成质量基线，但“工具支持”不能代替算子可执行或真实加速证明。

03 观点与建议

先用目标模型已支持的配置建立质量与容量基线；新论文只有在同总字节、同负载下有增量价值时才投入适配。

证据边界：官方文档， 2026-10-09 复核； alpha02 非正式版、非确认的十月新发布；部署依模型实践核对。

[I1a] msModelSlim · 版本说明 / alpha02 [I1b] V1 算法总览

量化 Attention： 低精主体与高精尾块需要联合核算

ops-transformer 主干公开目录 · 2026-10-09 复核 · KV Cache × 量化；关联激活 × 量化

01 发生了什么 • 原始事实

01 高精窗口接口

主干说明将 quant_flash_attn 从 15 输入扩至 18 输入，新增 v_tail 尾块高精窗口及配套元数据。

02 布局正确性修复

提交 26716275 描述真实 stride 传入地址计算，修复非连续 v_tail 被按连续布局寻址导致的精度错误。

03 可用范围待核对

目录说明在 CANN 9.2 TensorV2 环境验证； CANN 9.1 有既有版本检查限制。正式发布标签尚待确认。

02 为什么重要 • 研究分析

混合精度缓存：保质量也增加容量

高精尾块意味着不能把全部 KV 都按 MXFP8 计算。比较缓存总字节时，要纳入尾块、尺度与布局元数据。

论文方案与工程路径的连接点

KV 量化论文若需要高精残差窗口，可优先核对已有尾块接口；窗口策略、布局检查和 Attention 合计时延仍需验证。

03 观点与建议

把高精尾块列为 KV 量化的工程候选；先核对合法布局、窗口字节与版本，再测质量—容量—时延的取舍。

证据边界：主干目录公开变更说明；未重跑项目测试，提交精确日期未确认；主干能力不等于安装包已发布。

[I2] quant_flash_attn · 主干目录与提交描述

vLLM-Ascend 候选版：低精度支持必须细到模型和层

v0.27.1rc1 · 说明日期 09-24 / GitHub 发布 09-29 · 权重 / 激活 / KV Cache × 量化

01 发生了什么 • 原始事实

01 模型和硬件限定

MiniMax-M3 覆盖 Atlas 800 A3 、 950DT ； DeepSeek-V4-Flash 覆盖 950DT 。 A2 未充分验证。

02 量化路径不是全层同精度

MiniMax-M3 新增 W8A8 与 ModelOpt 兼容 MXFP8 ； fp8 缓存开关下， MSA / index 为 FP8 ， dense GQA 默认 BF16 。

03 配套基线明确

发布镜像配套 vLLM 0.27.1 、 CANN 9.1.0 、 HDK 26.1.1 、 PyTorch / torch_npu 2.10.0 系列。

02 为什么重要 • 研究分析

容量估计必须按层计算

全模型缓存不能统一按 C8 估算。要读取实际缓存类型、BF16 回退与各层占比，再计算并发容量。

算子和调度改变收益兑现方式

发布说明含稀疏 Attention 、索引与 TP 通信变化；研究比较要固定完整镜像，区分数值压缩收益与运行栈优化收益。

03 观点与建议

仅在声明支持的模型 / 硬件组合建立候选基线；先确认逐层 dtype 和回退，再测同质量与 SLA 下的容量及 TPOT 。

证据边界：官方候选发布说明；不是正式版或十月新发布，不代表 A2 等范围外组合可用；未有昇腾本地实测。

[I3] vLLM-Ascend v0.27.1rc1 · Features / Scope / Dependencies

vLLM-Ascend 正式补丁：压缩收益先过正确性门槛

v0.23.0.post1 · 说明日期 09-21 / GitHub 发布 09-22 · 既有补丁，本月复核

01 发生了什么 • 原始事实

01 KV 写入修复

DP 对齐 dummy run 前使各 KV group 的 slot mapping 失效，修复陈旧 KV-cache 写入。

02 量化缓冲区稳定性

修复 Atlas 300I DUO 的 MTP overlay 前缀缓存精度； ACL Graph 下 RL 重载时保持 W8A8 MXFP8 转换缓冲稳定。

03 KV Pool 依赖固定

锁定 memfabric_hybrid 与 memcache_hybrid 为 1.2.0；这些修复分属各自执行条件。

02 为什么重要 • 研究分析

错误复用会伪装成量化质量损失

KV 写入、前缀复用和权重重载的问题可能污染质量比较。应先排除状态错误，再归因于量化误差。

基线要包含真实生命周期

单次静态推理不足以覆盖复用、重载和分布式路径。仅对业务使用的路径补充回归，避免把相关补丁泛化为所有模型收益。

03 观点与建议

现网涉及上述路径时，先评估补丁基线并回归正确性；确认结果一致后，再比较论文方案的净性能收益。

证据边界：官方 Bug Fixes 与依赖变更；精度修复不等于吞吐提升，正式补丁也不证明所有模型 / 硬件可用。

[I4] vLLM-Ascend v0.23.0.post1 · Bug Fixes / Other Changes

昇腾研究判断：按技术地图确定投入顺序

权重 × 量化：优先穿刺规则精度布局与合法算子粒度； StagQ 、 DBW 及补偿方案只在极低总字节或多档部署约束下推进。
激活 × 剪枝： SpAx 优先针对卸载搬运； HBM 常驻模型必须另测动态选择、索引和不规则执行成本。
KV Cache × 量化： TaSQ 先核对质量、 TTFT 和容量收益，区分同 batch 时延与同 HBM 下吞吐。
KV Cache × 淘汰： Page-EntroKV 先核对物理页释放； DeferKV 补充淘汰时机，组合收益尚无证据。
KV Cache × 低秩 / GQA-MQA： AttSVD 与 SAGA 持续跟踪，分解刷新或训练改造成本须进入预算。

穿刺建议：固定模型、质量门槛与 SLA ；分别测驻留字节、 TTFT 、 TPOT 、同容量吞吐及准备成本。 GPU 论文结果不是昇腾预期收益。

HUAWEI

附录：同路线补充工作，按需展开而非堆入正文

权重 × 量化： StagQ 补充多档共享码流；有多精度部署需求再评估。
权重 × 剪枝 / 量化 / 低秩： DBW 补充分量预算联合优化，适合亚 2-bit 容量压力。
权重 × 量化 / 低秩： Align, Then Correct 补充质量恢复，但需计入统计和适配器成本。
KV Cache × 淘汰： DeferKV 补充首步真实查询决定淘汰时机。
KV Cache × GQA-MQA： SAGA 补充头结构改变，需训练 / 微调与算子改造。

TopK-Guided 、 OSFP4 、 Behavior-Preserving 仍保留在网页分析；原 PDF 无适合该模板的系统设计总览图，不用装饰图补位。

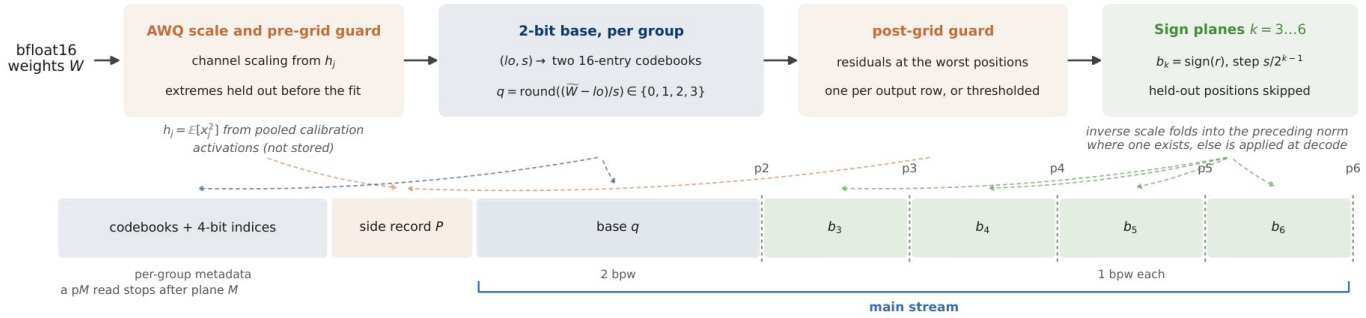
HUAWEI

StagQ （权重 × 量化）

StagQ: Constraint-Driven Multi-Precision Weight Quantization for LLMs

华为团队针对同一模型多精度部署需要存多份权重，采用共享前缀流与稀疏旁路补偿。研究价值是用一份编码提供多个精度档位，同时把异常值和元数据纳入实际码率；规则解码仍需专用内核。

技术方案 • 论文原图



共享前缀： 2-bit 基础流叠加 1-bit 细化平面。

共享元数据：各精度用同一仿射映射解码。

异常值旁路：编码前后保留难量化权重，计入总码率。

实验结果 • 原始条件

模型： Llama-3.1-8B 、 Phi-4 、 OLMo-2-7B 。

质量： MMLU 、常识任务及 WikiText-2 。

执行： A100 、 batch-1 、合成权重 GEMV ； 不是服务吞吐。

Method	Bit	Rate	MMLU	ARC-C	ARC-E	HS	PIQA	WG	CSR Avg
bfloat16	16	16.00	65.23	53.67	81.06	78.91	81.28	73.72	73.73
MatGPTQ	2	2.25	24.65	24.74	24.45	26.29	51.41	49.17	35.21
Any-Precision	2	2.01	23.82	24.57	34.09	27.90	57.24	50.36	38.83
AnyBCQ	2	2.38	35.33	37.29	62.67	62.76	73.94	57.93	58.92
StagQ-XXS	2	2.35	38.38	38.05	60.94	63.63	73.23	65.27	60.23
StagQ-XS	2	2.64	**48.67**	**41.98**	**70.12**	**70.05**	**75.52**	**67.32**	**65.00**

2-bit 较最强多精度基线提高 MMLU 3.1–7.0 个百分点。

4-bit 质量持平但码率更高，不能只比较名义位宽。

昇腾建议

条件研究：适合确有多档部署需求的模型。昇腾先比较总驻留字节与档位切换成本，再对旁路布局和 GEMV 做穿刺；单一位宽业务不应为共享流承担额外复杂度。

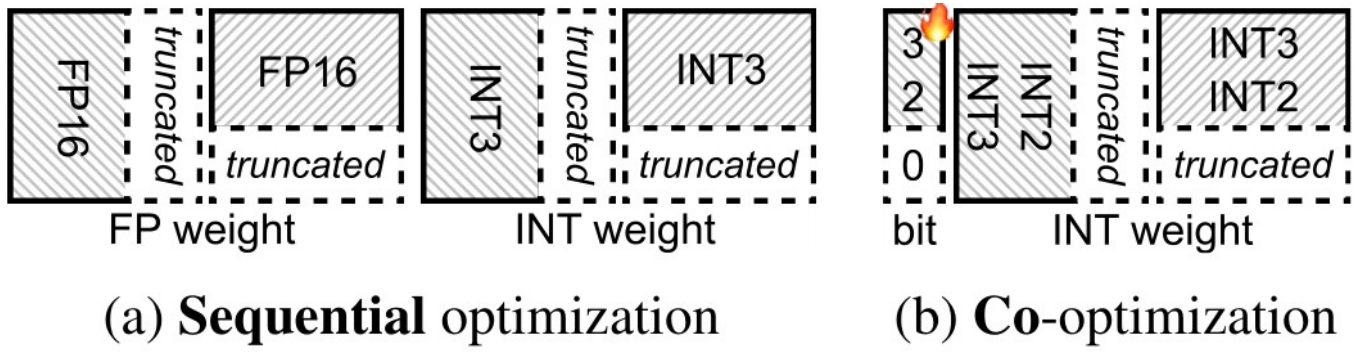
arXiv:2610.05977 v1 · Fig.3 / Table 1 · Table 1 (2-bit rows) excerpt · 点击查看论文原文

DBW （权重 × 量化 / 剪枝 / 低秩分解）

DBW： 联合优化分量剪枝与量化

亚洲大学团队针对先截断 SVD 、再量化的两阶段误差，联合学习分量位宽。 0-bit 表示删除分量，其余分量分配不同位宽。该方案争取极低存储预算下的质量，但校准训练与混合位宽执行需要额外成本。

技术方案 • 论文原图



联合目标：同时决定截断秩和保留分量位宽。

可微位宽： 0-bit 分量删除，预算在分量之间重新分配。

规则打包：按位宽分组执行，避免逐分量不规则访存。

实验结果 • 原始条件

模型： LLaMA 系列 7B–70B 及非 LLaMA 对照。

设置：平均 1.61-bit 、 group size 128 。

基线： PTQ 、 BiLLM 及两阶段 SVD 压缩； 8 项常识任务。

LLaMA	Method	Group	Bits	PIQA	ARC-e	HellaS	Wing	Race	ARC-c	LAMB-o	LAMB-s	Avg.
1-7B	FP16	-	16	78.67	75.29	56.99	70.01	40.29	41.81	73.57	67.82	63.06
	GPTQ	128	2	59.41	36.11	32.59	50.43	27.56	20.31	12.79	9.02	31.03
	SliM-LLM+	128	2	65.72	52.74	39.49	55.33	34.35	23.81	38.15	22.96	41.57
	OmniQuant	128	2	67.74	59.51	41.24	56.75	33.30	28.41	40.89	25.75	44.20
	PB-LLM	128	1.7(+1)	55.71	29.12	28.31	48.86	26.41	19.80	10.42	10.09	28.59
	BiLLM	128	1(+1.1)	61.10	40.99	31.80	53.67	30.14	20.64	23.15	16.48	36.00
	PTQ1.61	-	1.61	63.71	49.62	35.73	56.75	32.54	25.26	38.93	26.57	41.14
	DBW(Ours)	128	1.61	69.53	57.24	41.39	60.38	35.79	28.58	53.74	45.20	48.98

LLaMA-7B 常识均分 48.98% ， 两阶段 PTQ 为 41.14% 。

该 1.61-bit 质量结果不能替代昇腾端到端执行测试。

昇腾建议

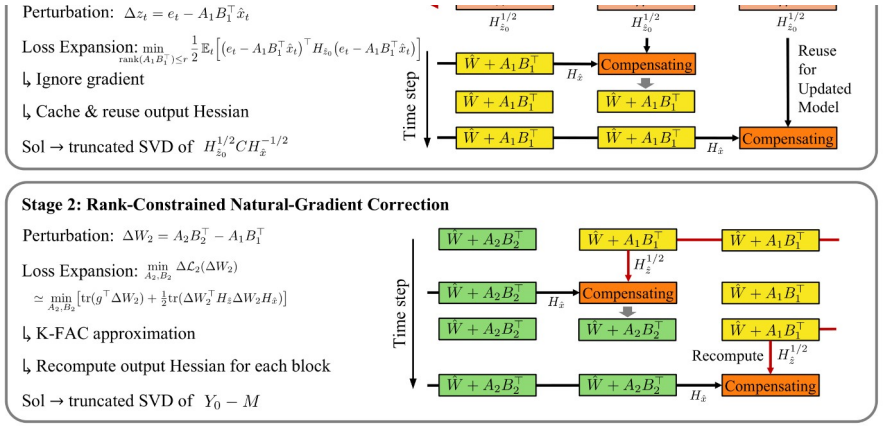
条件研究：业务需要亚 2-bit 权重时再评估。固定总字节预算比较质量，并计入低秩因子、尺度、重训和多个 GEMM 成本；先核对昇腾可执行的位宽集合，再做算法适配。

Align, Then Correct （权重 × 量化 / 低秩分解）

Align, Then Correct： 免训练的两阶段低秩补偿

汉阳大学与 Qualcomm 团队针对低秩补偿目标难以低秩拟合、只优化二阶误差的问题，先做 Fisher 加权非对称对齐，再校正剩余一阶误差。权重保持冻结，闭式求适配器；免训练不等于免校准。

技术方案 • 论文原图



输出对齐：用全精度与量化模型的不同输入构造目标。

统计重测：第一阶段补偿后重新采集梯度与曲率。

低秩校正：限秩自然梯度方向由截断 SVD 求解。

实验结果 • 原始条件

模型： Qwen3-8B/4B， 主实验 QuIP# 2-bit 。

校准： 128×2048 WikiText-2， rank 64 等设置。

质量： WikiText-2/C4 PPL， 7 项零样本任务。

FP16	9.73	15.24	69.38	13.64	19.84	66.73
QuIP#	12.43	19.19	62.81	21.11	29.21	57.47
+ EoRA	12.20	18.98	63.03	20.92	27.71	58.69
+ QERA	12.22	18.97	63.06	20.91	27.67	58.63
+ ProjQ	12.15	18.91	63.07	21.16	27.81	58.41
+ LQ-LoRA	11.62	17.95	64.29	16.75	23.34	59.66
+ Ours	**10.26**	**17.17**	**64.51**	**13.22**	**21.36**	**60.05**

Qwen3-8B WikiText-2 PPL： 12.43→10.26 。

Qwen3-4B PPL： 21.11→13.22； 还需计入适配器字节。

昇腾建议

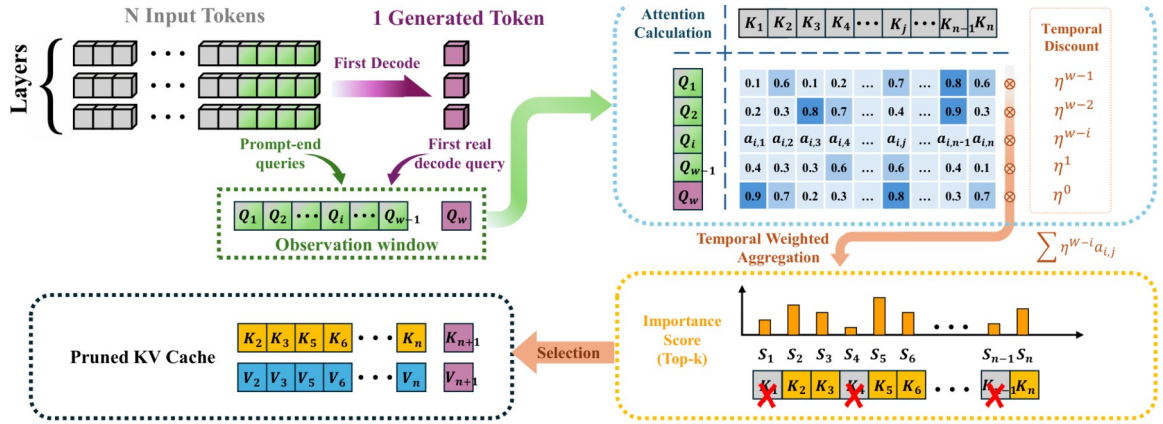
条件研究：对极低比特质量不足的模型，先比较同总容量下更高位宽与低秩补偿。昇腾穿刺需计入适配器 GEMM 、统计校准和并行通信；质量恢复成立之后再判断时延净收益。

DeferKV （KV Cache × KV Cache 淘汰）

DeferKV: Rethinking Eviction Timing for One-Shot KV Cache Compression

电子科技大学团队针对 prefill 末尾查询不能代表后续生成，把不可逆淘汰推迟到首个真实 decode 查询。结合提示与生成侧注意力再选 KV，不增加草稿模型或训练；其价值是改善淘汰时机而非改变压缩格式。

技术方案 • 论文原图



真实查询：首次 decode 时获取真实生成需求。

时间加权：近期 prompt 查询和 decode 查询联合打分。

一次淘汰：保留原方法预算结构，更换重要性估计。

实验结果 • 原始条件

模型： Qwen3-8B 、 Llama-3.1-8B 、 Mistral-7B 。

评测： 16 项 LongBench 、 RULER 和针检索。

比较： SnapKV 、 LAQ 、 SpecKV 、 LookaheadKV 及 Full KV 。

Method	Single-Doc QA			Multi-Doc QA			Summ.			Few-Shot			Synth.		Code		Avg.
	NrtvQA	Qasper	MF-en	HotpotQA	2WikiMQA	MuSiQue	GovReport	QMSum	MultiNews	TREC	TriviaQA	SAMSum	PCount	PR-en	LCC	RB-P	
Qwen3-8B, $B_{total} = 64L$																	
SnapKV	17.41	30.06	38.05	47.77	37.71	20.65	14.00	19.37	12.93	43.50	81.92	36.53	5.00	87.50	59.30	53.58	37.83
LAQ	18.99	**37.88**	43.31	53.88	41.35	23.24	**16.18**	19.40	14.78	66.00	88.40	**37.64**	5.50	94.50	62.31	55.91	42.45
SpecKV	19.61	29.97	**49.79**	51.03	36.97	22.14	13.27	**19.72**	**14.82**	37.50	73.63	36.71	6.00	95.00	45.15	46.62	37.37
LookaheadKV	18.22	32.27	40.12	47.66	38.01	23.58	14.61	18.36	13.18	46.95	83.29	36.69	5.00	90.40	59.06	54.28	38.86
DeferKV	**21.87**	35.37	45.97	**56.99**	**41.88**	**31.20**	14.81	19.52	13.52	**70.50**	**89.98**	37.44	**8.00**	**97.50**	**62.52**	**56.47**	**43.97**
Qwen3-8B, $B_{total} = 512L$																	
SnapKV	22.70	42.96	51.19	57.09	42.51	**34.94**	25.14	**23.44**	21.87	68.50	89.46	43.34	**9.50**	**100.00**	**68.74**	64.22	47.85
LAQ	23.16	43.58	52.63	56.16	43.02	34.36	25.46	22.02	21.94	71.00	**90.05**	43.35	**9.50**	**100.00**	67.92	64.72	48.05
SpecKV	24.38	43.27	**53.93**	58.07	42.90	31.48	**29.51**	23.24	**24.05**	71.00	89.96	29.60	4.00	99.00	56.84	56.85	46.13
LookaheadKV	23.10	43.67	52.21	56.86	43.12	34.91	25.46	22.71	22.08	71.00	89.97	**43.85**	**9.50**	99.00	68.01	**64.98**	48.15
DeferKV	**24.82**	**44.78**	51.96	**58.09**	**43.18**	33.83	26.04	22.74	22.17	**71.50**	**90.05**	43.70	**9.50**	**100.00**	67.55	64.02	**48.37**
Full KV	24.73	48.05	54.39	58.16	43.79	34.27	33.45	24.12	24.84	71.50	90.21	44.56	9.50	100.00	69.34	65.48	49.77

Qwen3-8B 、 KV 预算 512： LongBench 均分 44.96 ，SnapKV 38.46 。

RULER 跨 4K–128K 均分 81.36 ， Full KV 93.46 ；并非无损。

昇腾建议

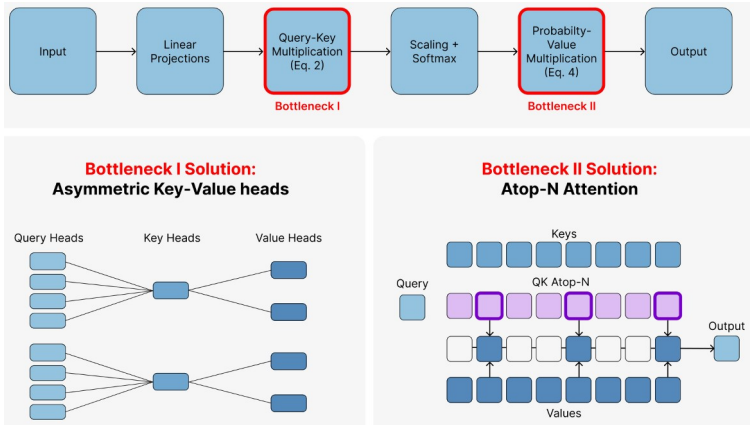
条件研究：长提示、短输出业务先比较同保留预算的质量和 TTFT 。昇腾核对首步延迟淘汰是否增加峰值 HBM ，并计入注意力取样、评分与页搬移；它可与页预算策略组合，但组合收益要另测。

SAGA （KV Cache × GQA / MQA）

More Value per Key: Asymmetric Sparse Attention for Faster LLM Decoding

Technion 等团队针对稀疏注意力后 QK 计算仍是瓶颈，减少 Key 头而保留更多 Value 头，再用近似 top-N 选择。技术价值是改变 K/V 结构以匹配瓶颈，但需训练或微调转换，不能作为普通模型的无损缓存插件。

技术方案 • 论文原图



非对称 K/V： 少量 Key 头减少 QK 访存与计算。

近似 top-N： 控制参与 PV 的候选，保留 Value 表达能力。

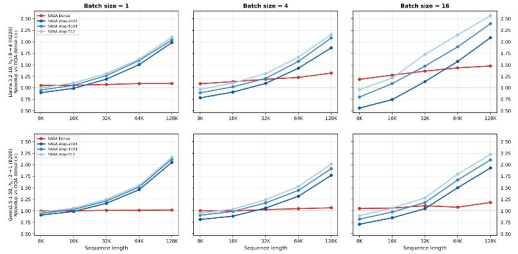
模型转换：蒸馏或微调适配新头结构，需要质量重验。

实验结果 • 原始条件

模型： Llama-3.2-1B 、 Qwen2.5-1.5B 。

平台： H200/B200； batch 1/4/16 、上下文 8K–128K 。

比较：作者同栈完整注意力 GQA， CUDA Graph 解码。



作者长上下文端到端解码加速超过 2×，模型最大 1.5B 。

从头训练质量接近 GQA； 不能外推现有大模型免训练收益。

昇腾建议

持续跟踪：适合有模型结构改造权限的研究线。昇腾先验证非对称头布局与算子支持，再比较同训练预算质量、同栈解码与转换成本；现有生产模型优先选择保持模型结构的 KV 压缩。

arXiv:2610.04753 v1 · Fig.1 / Fig.2 · v1 · 点击查看论文原文

Thank you.

把数字世界带入每个人、每个家庭、
每个组织，构建万物互联的智能世界。

Bring digital to every person, home, and organization for a fully connected, intelligent world.

Copyright©2021 Huawei Technologies Co., Ltd.
All Rights Reserved.

The information in this document may contain predictive statements including, without limitation, statements regarding the future financial and operating results, future product portfolio, new technology, etc. There are a number of factors that could cause actual results and developments to differ materially from those expressed or implied in the predictive statements. Therefore, such information is provided for reference purpose only and constitutes neither an offer nor an acceptance. Huawei may change the information at any time without notice.

HUAWEI