哪些压缩技术值得进入昇腾业务验证

在质量损失小于 1% 的要求下，判断技术能否降低实际推理成本。

快速阅读 · 约 8 分钟

7 页主线： 1–3 、 8–11
业务问题、关键证据、外部变化与投入取舍

深入阅读 · 约 25 分钟

阅读 1–11 页，按需跳转原表
机制、消融对照、测试边界与停止条件

开始阅读

材料截至 2026-10-09 ； 机制与指标复核 2026-10-15 。论文及厂商结果，不是本业务昇腾实测。

同一质量门槛下，压缩必须改善真实服务表现

两类业务分别评估。 LLM 以 Qwen3.8-27B 为例，研究范围不限于该模型。

LLM 服务	短输入与低并发：核查权重读取 长上下文与高并发：核查 KV 容量	关注首词、逐词、吞吐和峰值内存 瓶颈测量决定采用哪条路线
领域模型	降噪、翻译等既有模型 按实际网络结构判断可压缩对象	关注音质 / 翻译质量与端到端时延 无自回归缓存时不套用 KV 方案

共同约束： 310P 、 910B 及 950 分别建立基线； 950 型号待确认。
质量损失小于 1% ，须固定业务指标口径与关键子任务，不能用论文平均分代替。

本期问题：哪项技术值得先验证，什么结果足以支持继续投入？

三类论文证据，支持三种不同的研究选择

下列数值来自不同实验，不能按降幅排名。先看证据能支持什么，再决定研究顺序。

AlignQuant **执行优化候选**	Llama-3.2-3B / A100 / B1 TPOT −56.1%，驻留显存 − 54.6% TTFT 增加 12.6%	有系统收益，也有首词代价 权重读取是瓶颈时优先验证 尚未满足全部任务损失 <1%
Align, Then Correct **质量恢复候选**	Qwen3-8B / 3-bit + rank64 常识均分 68.10→69.11% FP16 为 69.38%	低比特质量不达标时再研究 没有在线时延和净显存结果 必须与同总字节升位宽比较
AttSVD **KV 容量候选**	Qwen3-8B / 32k： KV 减少 49.8% 另一质量实验： 51.8→51.8 时延未报告，容量与质量分测	仅在长上下文容量受限时启动 重建开销和峰值内存仍待测 不能由 KV 减半推出吞吐翻倍

AlignQuant • 原表 19 页

arXiv:2610.07457v1

ATC • 原表 26 页

arXiv:2610.08164v1

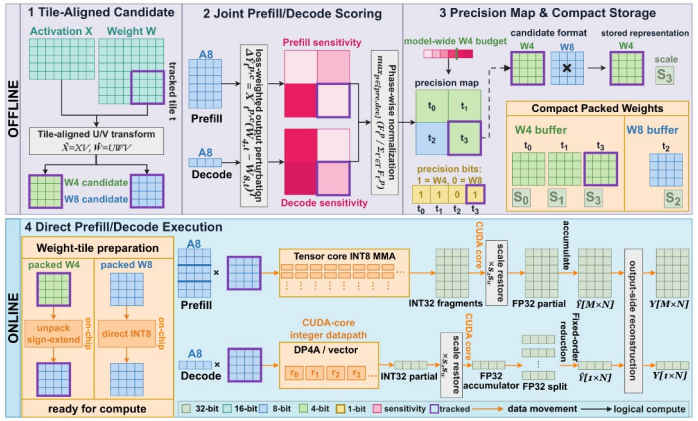
AttSVD • 原表 23 页

arXiv:2610.06927v1

AlignQuant： 用计算块对齐 W4/W8 分配与权重读取

混合精度若与硬件计算块错位，权重变小也未必变快。 AlignQuant 统一按 64×64 块分配位宽、打包和执行，并同时保护输入处理与逐词生成阶段的敏感块，让精度取舍与实际权重读取对应。

关键技术 | 核心思路与实现方法



双阶段敏感度：权重按 64×64 分块，在 A8 激活下分别测输入处理和逐词生成的 8→4-bit 输出扰动，再用损失梯度加权。

块级混合精度：把两阶段分数各自归一化后取较大值：任一阶段敏感的块优先留 8-bit ，其余按总预算用 4-bit 。

紧凑存储与解包：每块仅存选中的一份权重；逐词生成时按 4-bit 紧凑读取、片上展开 INT8 ，减少带宽占用但仍付解包成本。

关键效果 | 基线 → 论文方案

Llama-3.2-3B-Instruct | A100 40GB | BF16 对照
B=1； 输入 128 / 输出 512 tokens； 60% W4 + 40% W8
质量： WikiText-2 及 MMLU 等 6 任务；系统负载未列文本集。

TTFT	**17.47 → 19.67 ms	增加 12.6% （更慢）**
TPOT	**17.19 → 7.54 ms/token	减少 56.1%**
内存	**驻留 5.99→2.72 GiB （– 54.6% ） 峰值 6.09→2.72 GiB （– 55.3% ）**
质量	**MMLU 60.66→60.53% （– 0.13 个百分点） WikiText-2 PPL 12.49→12.61 （ +0.96% ）**

吞吐 58.18→132.28 tok/s； HellaSwag 相对下降 1.09% ，不能宣称全部质量损失 <1% 。

查看实验原表 →

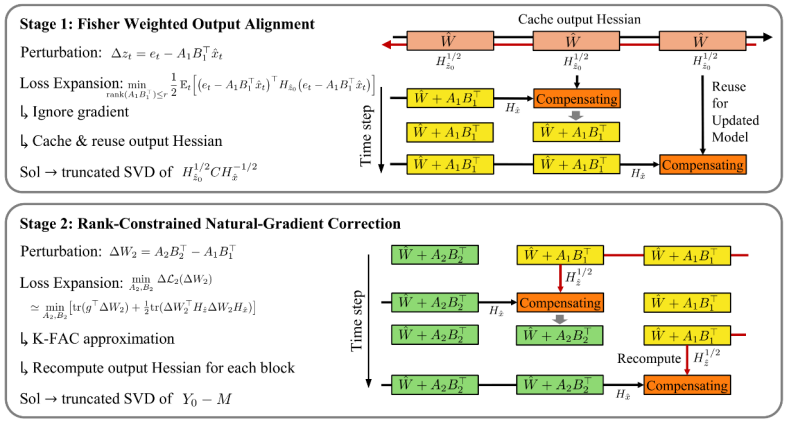
Metric	Unit	Upper Ref. BF16	Lower Ref. W4A8	Ours *AlignQuant*	Others GPTQ	AWQ	MixLLM	SFMP
TTFT ↓	ms	17.47	22.51	**19.67**	21.99	23.07	27.48	86.99
TPOT ↓	ms/token	17.19	21.12	**7.54**	20.77	21.78	24.05	82.33
Throughput ↑	tok/s	58.18	47.33	**132.28**	48.13	45.91	41.58	12.15
Resident GPU Mem. ↓	GiB	5.99	2.08	2.72	**2.11**	2.12	2.87	2.15
Peak VRAM ↓	GiB	6.09	2.16	2.72	**2.20**	2.21	2.92	2.37
Energy ↓	J/1K tokens	2280.68	2322.34	**1267.92**	2047.43	1732.24	2172.71	22535.65

研究判断 优先核对紧凑权重能否直接执行。固定总字节比较选位方法，再固定选位比较加载路径；解包成本抵消读取收益时停止完整移植。

Align, Then Correct：先补累计误差，再校正损失方向

仅拟合本层权重误差会漏掉上游输入偏移，输出接近也未必恢复任务质量。该方法冻结低比特权重：先做 Fisher 加权的双输入输出对齐，再以自然梯度校正任务损失，最终保持同一低秩预算。

关键技术 | 核心思路与实现方法



非对称输出对齐：原模型与量化模型各用自身前层产生的输入，拟合两者实际输出差；低秩分支同时补偿本层误差和上游累计偏移。

Fisher 加权补偿：用完整输出 Fisher 衡量误差对损失的影响，再以截断 SVD 求补偿分支，使有限 rank64 优先修复敏感方向。

自然梯度校正：在已补偿模型上重采激活和梯度，沿受限自然梯度方向校正；对整个分支再截断到 rank64，避免补偿秩翻倍。

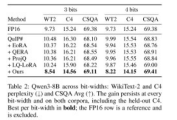
关键效果 | 基线 → 论文方案

Qwen3-8B | A100 40GB | QuIP# 3-bit + rank64
对照原 QuIP# 3-bit 及 FP16； WT2/C4 、 7 项常识零样本
校准：第一阶段 128×2048，第二阶段 16×512 tokens 。

TTFT	**未报告在线首词时延**
TPOT	**未报告在线逐词时延**
内存	**未报告推理显存减少量** **rank64 额外 264–349 MB （跨模型范围）**
质量	**常识均分 68.10→69.11%； FP16 为 69.38%** **距 FP16 −0.27pp； WT2 PPL 10.48→8.54**

2-bit 常识均分 64.51%，不能拿 2-bit 体积配 3-bit 精度； 2-bit 离线构建约 63 分钟。

查看实验原表 →



Method	3 bits WT2	3 bits C4	3 bits CSQA	4 bits WT2	4 bits C4	4 bits CSQA
FP16	9.73	15.24	68.38	9.73	15.24	69.38
QuIP#	10.48	16.30	68.10	9.99	15.54	68.83
+ EoRA	10.37	16.22	68.54	9.94	15.53	68.76
+ QERA	10.30	16.21	68.55	9.95	15.53	68.91
+ ProjG	10.36	16.21	68.40	9.96	15.55	68.84
+ LQ-LoRA	10.24	15.90	68.22	9.87	15.46	69.00
+ Ours	**8.54**	**14.06**	**69.11**	**8.22**	**14.18**	**69.41**

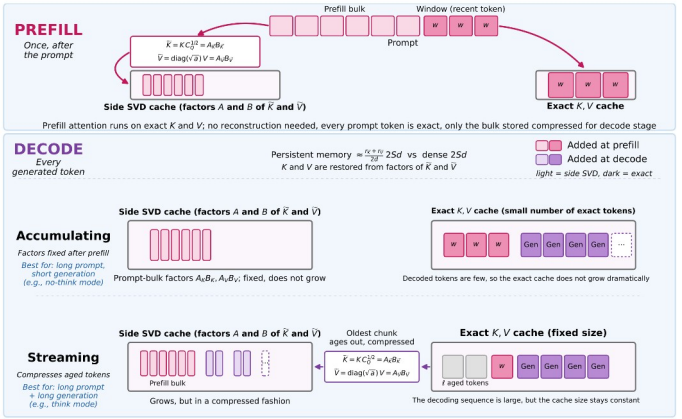
Table 2: Qwen3-8B across bit-widths. WikiText-2 and C4 perplexity (↓) and CSQA Avg (↑). The gain persists at every bit-width and on both corpora, including the held-out C4. Best per bit-width in **bold**; the FP16 row is a reference and is excluded.

研究判断 仅在低比特质量不达标时启动。对比无补偿、单阶段、两阶段及同总字节升位宽，计入 rank64 分支的时延和内存后再决定。

AttSVD： 保留全部 token， 用注意力加权选择低秩方向

删 KV 会丢失 token， 普通 SVD 又只追求 KV 数值接近，未必保住注意力输出。 AttSVD 先按注意力作用加权，再做低秩分解，保留全部 token 位置，但只存较少方向并在计算时重建。

关键技术 | 核心思路与实现方法



注意力加权：用 Query 协方差加权 Key， 使误差贴近注意力分数；按每个 token 收到的注意力总量加权 Value， 强调输出贡献。

低秩因子存储：对加权 KV 做截断 SVD， 只存 “ token× 秩”和 “秩 × 通道”两个因子；保留全部位置，用较少方向近似原矩阵。

精确尾部与重建：解码时逐层重建 KV， 再拼上近期原值； Stream 将离开窗口的老 token 分块压缩，窗口有界但压缩块仍累计。

关键效果 | 基线 → 论文方案

Qwen3-8B， BF16 、 rank64； KV 内存测试 32k 上下文。
质量： LongBench 九任务、 1750 例， 50% 缓存；与内存分测。
全文未找到明确 GPU 型号、 batch 及分项时延结果。

TTFT	**未找到实测；在线 SVD 引入的预处理耗时尚不明确。**
TPOT	**未找到实测；按层重建及 Stream 分块 SVD 成本须补测。**
内存	**Qwen3-8B@32k： KV 张量 4.500→2.260 GiB， – 49.8%； 非整模型峰值。**
质量	**同模型 LongBench 均分： Dense 51.8→Accum 51.8/Stream 51.9； 非逐任务无损。**

Phi-4 同为 50% 缓存时 36.7→36.0， 相对损失 1.91%； 不能将小于 1 分写成小于 1% 。

查看实验原表 →

Table 1: Measured KV-cache memory on Phi-4-14B (40 layers, 40 query / 10 KV heads) and Qwen3-8B (36 layers, 32 query / 8 KV heads); d=128, bf16.

	Phi-4-14B			Qwen3-8B			
	Rank r	KV @32K (GiB)	Measured ratio	KV @9.4K (GiB)	KV @32K (GiB)	Measured ratio	KV @9.4K (GiB)
Dense cache	128	6.250	1.000	1.804	4.500	1.000	1.299
AttSVD (ϵ=0.50)	64	3.139	0.502	0.916	2.260	0.502	0.660
AttSVD (ϵ=0.75)	32	1.571	0.251	0.459	1.131	0.251	0.330
AttSVD (ϵ=0.875)	16	0.787	0.126	0.231	0.567	0.126	0.166

研究判断 仅在 KV 容量限制并发时启动。比较同预算 raw SVD 与加权 SVD， 把分解、重建、尾部和临时缓冲计入，验证同响应约束下能否多承载请求。

另外七篇保留研究价值，本轮不同时展开

取舍依据是业务适用性、质量代价与系统证据。当前配置不优先，不等于技术方向没有价值。

SpAx	论文仅验证权重卸载场景，性能与质量预算未对齐	详见 12
TaSQ	1-bit 长推理质量相对下降 9.87%，先研究更保守位宽	详见 13
Page-EntroKV	页预算未兑现为实测 HBM，严格检索存在失败	详见 14
StagQ	共享码流适合多精度交付， 2-bit 质量仍有明显差距	详见 15
DBW	1.61-bit 八任务准确率下降 14.13 个百分点	详见 16
DeferKV	淘汰时机值得研究，首步和稳态时延仍需分测	详见 17
SAGA	头合并需蒸馏， Atop-N 性能与质量配置须分别核验	详见 18

原机制、负向结果和实验原表完整保留在后续备查页。

外部变化支持权重研究，也提醒我们核算完整成本

沿用截至 10 月 9 日已核验的三项材料。事件、影响与本轮动作分别陈述。

Mistral Large 4 **10 月 6 日预览公告**	披露 1T 总参数、 52B 激活参数 权重当时计划月底发布 规格与发布计划，非压缩成果	容量预算仍要覆盖全部权重 跟踪格式与专家驻留方案 不据此启动未公开模型适配
openTPU **10 月 1 日作者实验**	Qwen3.5-2B， INT8 对照 4-bit wall 解码 8.00→12.03 tok/s 计入尺度后 4.25 bit/weight	约 1.50 倍是原表计算值 借鉴总字节和端到端测量 FPGA 倍数不能外推到昇腾
Strands Decider 2B **10 月 1 日官方介绍**	2B 主干改为选项打分 一次前向，不能通用生成 属于任务专用模型设计	只对路由 / 分类场景有直接启示 本轮降噪 / 翻译不据此转向 先确认任务再讨论模型压缩

三项原始事实与来源： 29–31 页

昇腾落地取决于格式、算子与引擎能否贯通

先在已确认的模型和实际硬件上建立合法基线。 310P 、 910B 、 950 不能共用未核验的支持结论。

msModelSlim **量化输出**	文档列出 GPTQ 、 AWQ 等路径 alpha02 为内测版本 具体模型与模式按实践核对	先确认可导出格式、量化粒度 建立现有方案质量 / 字节基线 “收录算法”不等于目标模型支持
ops-transformer **合法执行**	主干量化 Attention 含高精尾块 版本和 stride 布局影响正确性 主干能力不等于安装包已发布	核对布局、 scale 与尾块接口 检查是否紧凑读取及中途展开 实际内核决定容量与时延代价
vLLM-Ascend **服务集成**	候选版支持范围细到模型和硬件 部分层缓存仍使用 BF16 正式补丁修复特定 KV 生命周期	固定完整软件镜像和逐层 dtype 先回归复用、重载与缓存正确性 再评估同业务 SLO 的净收益

版本范围、具体变更与官方来源： 32–35 页

一次实验只回答一个因果问题

先确认硬件型号、模型版本和可执行格式。下列是拟议实验，不是已完成的昇腾测试。

AlignQuant **少读权重是否真提速**	同总字节，比较固定与敏感度选位 固定选位，比较紧凑与展开执行 拆分搬运、解包、矩阵核耗时	业务质量过线， TPOT/ 吞吐有净收益 TTFT 满足既有响应约束 解包吞掉收益则停止该执行路径
ATC **补偿是否优于升位宽**	同底座：无补偿、单 / 双阶段 补偿组同 rank ，再比同字节升位宽 独立测试集，计入在线分支成本	关键业务子集质量均过线 总成本优于可部署替代方案 仅校准集改善或被基线支配则停止
AttSVD **省 KV 能否增加服务容量**	同 KV 预算：普通 vs 加权 SVD 按阶段核算分解、重建耗时 测完整生命周期峰值 HBM	同质量、同响应下提高并发 不以放宽时延换取吞吐 检索失败或峰值未降则回退

每轮交付原值与变化：质量、 P50/P95 TTFT 与 TPOT 、稳态吞吐、峰值 HBM ； 领域模型改测端到端时延。

建议先投入一条主线，两条支线按证据启动

本期能做的是确定验证优先级。下一阶段用同配置实测决定继续、调整或停止。

优先验证

AlignQuant： 权重读取确为瓶颈且格式可执行时，验证块级选位与紧凑读取。目标是质量过线后的 decode 净收益。

按条件追加

低比特质量不过关： ATC 与同总字节升位宽竞争。

长上下文容量不足： AttSVD 验证同响应约束下并发。

本轮不铺开

不把其余七篇同时转为适配项目。

领域模型先走权重量化与误差补偿，按真实结构筛选。

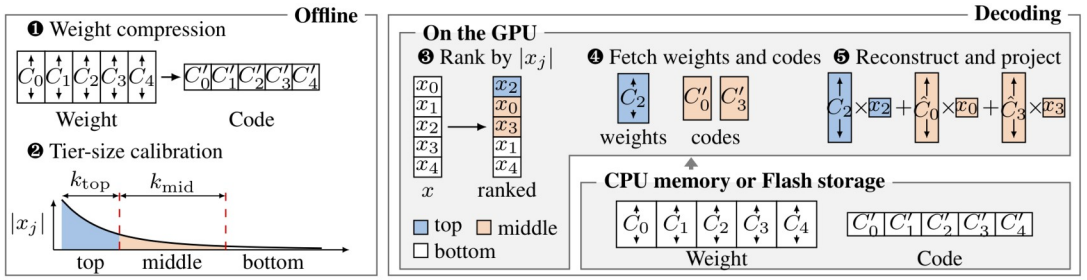
需要确认的投入：目标栈与业务样本、可执行格式检查、单项对照实验；结果成立后再扩大适配。

返回本期筛选

SpAx：让中等贡献的权重列读近似值，减少卸载搬运

权重卸载时，逐词搬运可能成为瓶颈；继续增加跳过比例又会损伤质量。SpAx 把“读或不读”改成原值、2-bit 近似和跳过三档，让中等贡献的列少传字节但仍参与计算。

关键技术 | 核心思路与实现方法



激活分档：按每个 token 的激活大小重新分档：大激活列读原格式，中档读近似，小档跳过；各档数量由离线校准预算确定。

2-bit 近似：每列独立存 2-bit 近似码，选中后在 GPU 还原；误差再乘该列较小的输入激活，比直接删列保留更多输出贡献。

列聚合读取：共享同一输入的投影矩阵，将对应权重列连续存放，再合并相邻读取请求；减少 CPU 或 SSD 卸载的碎片传输。

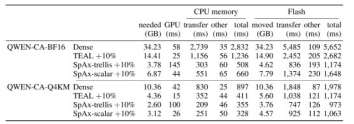
关键效果 | 基线 → 论文方案

Qwen3.6-27B | RTX4090 / PCIe4.0×8 | B=1
仅 FFN 从 CPU 卸载； Dense BF16 vs trellis 近似（ +10% PPL 容忍）
4 步预热 + 8 步解码；输入长度未报告。质量另见 Table 10 。

TTFT	**未报告首词时延**
解码	**每 token 2832→508 ms （– 82.1% ）** **论文解码测时；未报告完整服务 TPOT**
内存	**驻留 / 峰值显存未报告** **需传输权重 34.23→3.78 GB/token （– 89.0% ）**
质量	**WT2 PPL 7.40→8.16； ARC-C 60.3→57.6%** **性能与质量的读取预算未对齐，不能视作同配置收益**

SSD 实搬 34.23→4.62 GB/token （– 86.5% ）；减少搬运不能等同减少显存或模型总存储。

查看实验原表 →



		CPU memory needed (GB)	GPU (ms)	transfer (ms)	other (ms)	total (ms)	Flash moved (GB)	transfer (ms)	other (ms)	total (ms)
QWEN-CA-BF16	Dense	34.23	58	2,739	35	2,832	34.23	5,485	109	5,652
	TEAL +10%	14.41	25	1,156	56	1,236	14.90	2,452	205	2,682
	SpAx-trellis +10%	3.78	145	303	60	508	4.62	836	193	1,174
	SpAx-scalar +10%	6.87	44	551	65	660	7.79	1,374	230	1,648
QWEN-CA-Q4KM	Dense	10.36	42	830	25	897	10.36	1,848	87	1,978
	TEAL +10%	4.36	15	352	44	411	5.60	1,038	121	1,174
	SpAx-trellis +10%	2.60	100	209	46	355	3.76	747	126	973
	SpAx-scalar +10%	3.12	26	251	50	328	4.57	925	112	1,063

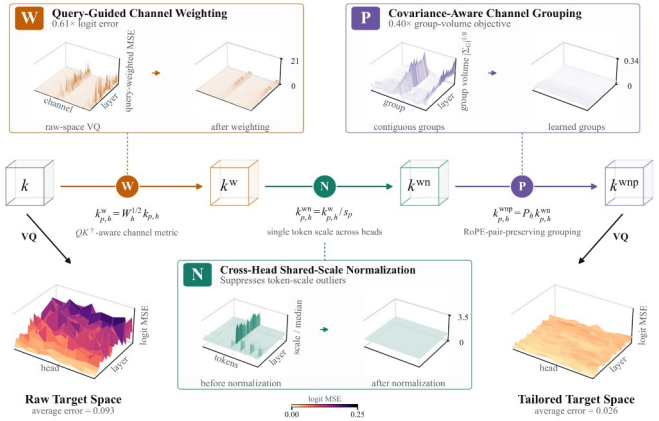
研究判断 只在业务确实需要权重卸载时研究三档读取。当前配置的质量代价超过业务目标，应先提高读取预算并测任务质量；达到 <1% 损失后，再考虑把列聚合与近似解码迁移到昇腾。

返回本期筛选

TaSQ： 先重整 Key 分布，再用小码本压缩 KV

极低比特码本很小，直接拟合 Key 容易把容量浪费在异常值和不重要的方向。 TaSQ 先按注意力敏感度重整 Key 分布，再把向量换成码本索引，以更少字节保存注意力真正依赖的信息。

关键技术 | 核心思路与实现方法



Query 引导加权：用校准 Query 估计各 Key 通道对注意力分数的影响，量化前据此缩放通道，让码本优先降低重要方向的误差。

归一化与分组：同一 token 的各 Key 头共用尺度以抑制异常值，再按协方差把相关通道分组，使小码本更容易拟合。

向量码本解码：把每组 Key 向量换成最近码字的索引，仅保存索引和尺度；Attention 中查表还原，并融合位置旋转。

关键效果 | 基线 → 论文方案

性能： Qwen3-4B-Thinking-2507 ， 单卡 RTX 6000 Ada ， SGLang 。
吞吐： 2k 入 /32k 出； TTFT： 8k–32k 输入、 batch=1 。
质量：同模型， AIME24/25 、 LCB-v6 、 SciBench 三种子均分；性能分测。

TTFT	**比 BF16 增加 10%–14% （ 8k–32k 输入）； 首 token 更慢。**
TPOT	**未找到独立 TPOT 结果；不能由吞吐倍数换算。**
内存	**总显存未报告；量化区约 1.258 bit/ 元素 比 BF16 推算少 92.1% ， 码本与精确窗口另计**
质量	**Long-CoT 均分： BF16 67.18→60.55 ， – 6.63 分；相对损失 9.87% 。**

峰值吞吐 220.8→412.6 tokens/s ； 各自最大 batch 从 6→84 ， 非同 batch 提速。

查看实验原表 →

Table 2: Long-CoT reasoning performance under low-bit KV cache quantization. We report the mean and standard deviation over three seeds. Bold denotes the best quantized result; higher is better.

Model	Method	Bits (K/V)	AIME'24	AIME'25	LCB-v6	SciBench	Avg.
Qwen3-4B-Thinking-2507	BF16	16.000/16.000	74.44±1.92	74.44±5.09	45.85±0.62	73.99±0.43	67.18±1.37
	CQ	1.250/1.250	26.67±3.33	14.44±5.09	18.99±0.44	54.00±0.94	28.52±1.54
	NovaKV	1.375/1.250	7.78±1.92	6.67±3.33	9.16±0.38	27.94±2.08	12.89±1.10
	NSNQuant	1.238/1.238	44.44±6.94	38.89±1.92	34.66±0.33	68.69±0.55	46.67±1.81
	TaSQ	1.266/1.250	**68.89±1.92**	**56.67±3.33**	**43.00±0.47**	**73.65±0.60**	**60.55±0.98**

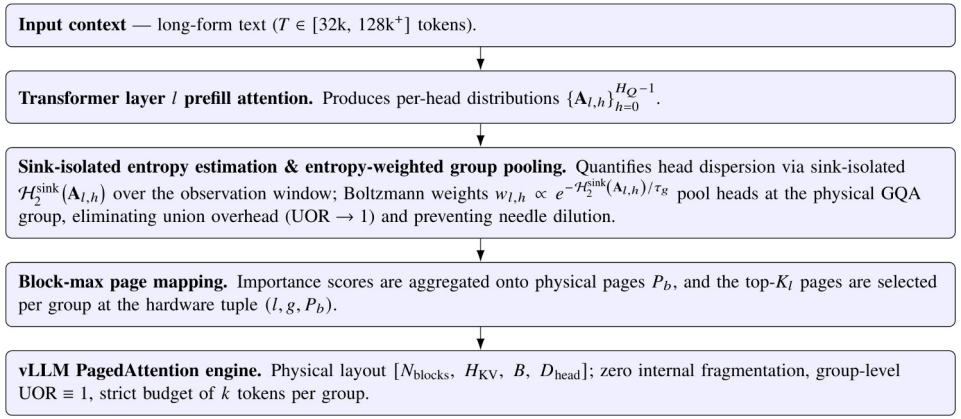
研究判断 先在昇腾验证高于 1-bit 的 KV 向量量化与 Attention 查表融合，固定模型和并发后分别测 TTFT 、 TPOT 。当前质量损失明显，只有业务集损失小于 1% 且总时延达标，才推进更低位宽。

返回本期筛选

Page-EntroKV： 先合并共享组评分，再按页淘汰 KV

GQA 各 Query 头单独选 KV 再取并集容易超预算，简单平均又会冲淡少数检索头的信号。 Page-EntroKV 先在共享组内按熵加权评分，再按页取舍，解决组内选择冲突。

关键技术 | 核心思路与实现方法



隔离 sink 干扰：仅在计算熵时排除首部 sink 并重新归一化，避免“只盯开头”的低熵头被误判为检索头；不是删除这些 token 。

组内熵加权：在共享同一份 KV 的 Query 组内，用负熵 softmax 加权汇总 token 分数；关注少数有效位置的头权重更高。

页级 Top-k 选择：页分数取页内最高 token 分数，再按配额保留高分页；避免逐头各选再并集，但跨 KV 组物理页仍需取并集。

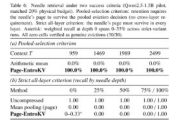
关键效果 | 基线 → 论文方案

Qwen2.5-1.5B-Instruct； 单卡 T4； HF eager， 逻辑分页 16 tokens 。
pilot 上下文约 0.9k–8.2k； 检索测试≤ 2.5k， 保留预算 20% 。
A100/vLLM/128k 是后续计划，尚非已测配置。

TTFT	**作者明确尚无服务级 TTFT 实测。**
TPOT	**作者明确尚无服务级逐 token 时延或吞吐实测。**
内存	**20% 是逻辑页保留预算； KV 字节、整模型显存与峰值 HBM 均未实测。**
质量	**20% 预算：单次池化保留率 100%； 严格全层保留在 25%–75% 位置为 0% 。**

LongBench 仅 4×20 例，缺 Full KV 同口径基线；不能计算精度损失，也不能宣称无损。

查看实验原表 →



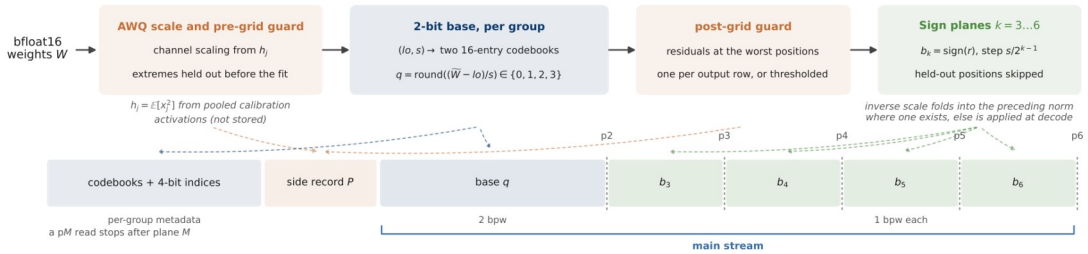
研究判断 先在 vLLM-Ascend 接入“组内汇总后按页淘汰”， 分开记录组内保留量、跨 KV 组页并集和实际释放的 HBM； 用全层检索与业务问答验证损失小于 1%， 再比较 TTFT 与 TPOT 。 20% 逻辑保留预算不能直接写成 80% 显存节省。

返回本期筛选

StagQ： 共享 2-bit 底码，追加细化位形成多档权重

多精度部署常要为每个位宽另存一份权重。 StagQ 把 2-bit 底码与细化位写入共享码流：少读层数省字节，多读层数细化同一权重；另存极值，防止它们拉宽整个量化网格。

关键技术 | 核心思路与实现方法



前缀细化编码：先存 2-bit 底码，再按残差正负追加 1-bit 细化层；每层让量化间隔减半，截取不同前缀即可读取不同位宽。

共享仿射解码：将底码和细化位拼成整数，由共享基准参数推导该档缩放与偏移；一次仿射解码还原权重，无需逐权重查表。

极值旁路保护：拟合量化网格前先分离极值，固定网格后再保护高误差值，避免拉宽全组格子；旁路记录每档都要读取，增加码率。

关键效果 | 基线 → 论文方案

质量： Llama-3.1-8B； StagQ-XXS 2-bit / 2.35 bpw
对照 AnyBCQ 2.38 bpw 与原始 BF16； MMLU 5-shot / WT2
执行实验： A100 、 B=1 、合成权重，不能视作真实模型收益。

TTFT	**未报告**
TPOT	**真实模型 TPOT 未报告** **合成权重速度含融合差异，不换算服务时延**
内存	**逻辑 2.35 bpw； 实际读取 2.47 bpw** **完整驻留 / 峰值显存未报告**
质量	**MMLU： AnyBCQ 35.33→StagQ 38.38%** **原始 BF16 为 65.23%， 仍低 26.85 个百分点**

逻辑码率相对 16-bit 少 85.3% 是格式核算；不能写成整模型显存减少 85.3% 。

查看实验原表 →

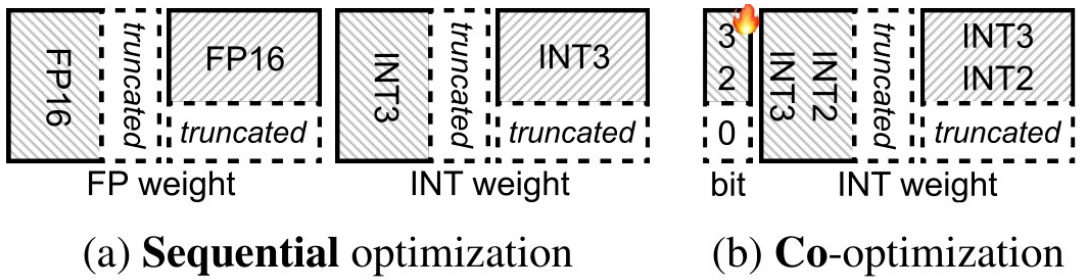
Method	Bit	Rate	MMLU	ARC-C	ARC-E	HS	PIQA	WG	CSR Avg
bfloat16	16	16.00	65.23	53.67	81.06	78.91	81.28	73.72	73.73
MatGPTQ	2	2.25	24.65	24.74	24.45	26.29	51.41	49.17	35.21
Any-Precision	2	2.01	23.82	24.57	34.09	27.90	57.24	50.36	38.83
AnyBCQ	2	2.38	35.33	37.29	62.67	62.76	73.94	57.93	58.92
StagQ-XXS	2	2.35	38.38	38.05	60.94	63.63	73.23	65.27	60.23
StagQ-XS	2	2.64	**48.67**	**41.98**	**70.12**	**70.05**	**75.52**	**67.32**	**65.00**

研究判断 只有存在多精度交付需求时才优先研究共享码流。先检验 4-bit 及更高档位的业务质量、实际总字节和切档开销； 2-bit 当前质量差距过大，合成权重速度也不足以支持昇腾上线判断。

DBW：在同一预算内，联合决定删哪些分量、各留几位

先剪枝再量化，会先锁死删哪些分量，再决定剩余位宽。 DBW 把二者合成一个预算问题：联合学习 SVD 分量及其位宽， 0-bit 即删除，在相同存储下权衡保留更多方向还是提高精度。

关键技术 | 核心思路与实现方法



(a) **Sequential** optimization (b) **Co**-optimization

可学习分量位宽：对权重做 SVD ，将每个分量的位宽设为可学习变量；0-bit 直接删除该秩方向，其余分量按不同位宽量化。

联合预算优化：固定总位预算，以原模型块输出为目标，联合学习分量、位宽和矩阵预算；熵约束集中奇异值能量，利于截断。

分组低秩执行：删除 0-bit 分量后，将其余分量按位宽分组打包，分别执行低秩矩阵乘；少存权重，但须核算双矩阵乘与启动开销。

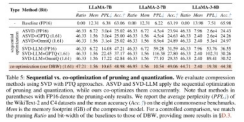
关键效果 | 基线 → 论文方案

LLaMA-2-7B | 1.61 bpw； group=128 | FP16 对照
校准 RedPajama 4096×2048； 测试 WT2/C4 + 8 项零样本
权重字节和质量为模型级； RTX3090 内核测时是另一实验。

TTFT	**未报告首词分项数值**
TPOT	**未报告逐词分项数值** **INT2 单 block GEMM 加速不能替代模型 TPOT**
内存	**权重占用 12.31→1.56 GB （– 87.3% ）** **含量化参数；不是运行时峰值 HBM**
质量	**8 任务准确率 63.19→49.06% （– 14.13pp ）** **WikiText-2 PPL 5.47→8.78**

GB 沿用论文单位；权重占用含 embedding 与量化元数据，不包含请求 KV 或激活。

查看实验原表 →

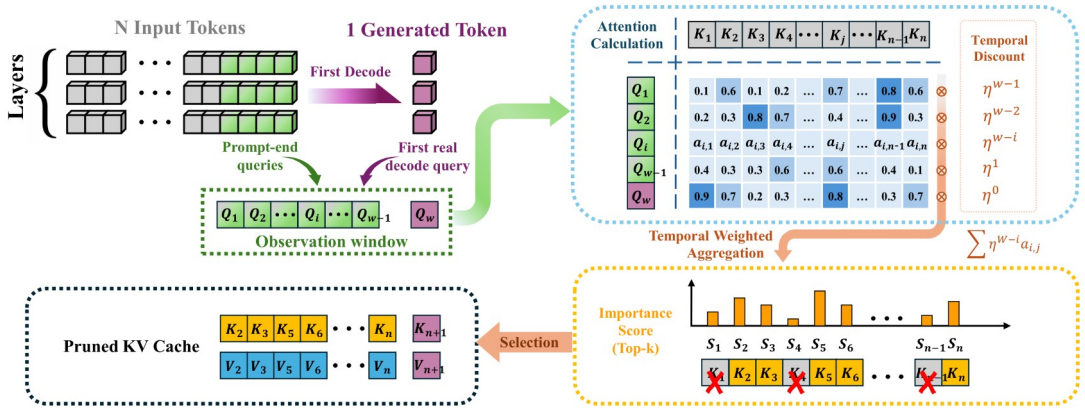


研究判断	当前 1.61-bit 配置用于容量极限研究，不宜直接迁移生产。若容量确实无法满足，先提高预算找质量拐点，并与同总字节量化比较；达到质量要求后再核查低秩双 GEMM 在昇腾的执行收益。

DeferKV： 先看一次真实生成需求，再决定删哪些 KV

模型读提示词与生成答案时需要的信息不同，只在 prefill 末尾选 KV 可能误删。 DeferKV 将首次淘汰推迟一个解码步骤，把真实生成 Query 加入评分，再沿用原淘汰器完成选择。

关键技术 | 核心思路与实现方法



延后首次淘汰：先保留完整提示词 KV ， 等首个生成 token 回送模型后取得真实 Query ； 用实际生成需求修正淘汰，避免过早误删。

时间加权评分：把首个解码 Query 与最近提示词 Query 组成观察窗口，越早的 Query 按时间指数降权，让评分更靠近生成阶段需求。

复用原有淘汰器：新分数交给现有淘汰器，保留其平滑、预算和 Top-k 逻辑；无需重训，但完整提示词 KV 须多保留一个解码步骤。

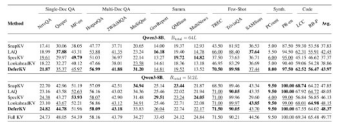
关键效果 | 基线 → 论文方案

Qwen3-8B ； A100 80GB ； batch=1 、贪心解码。
效率： 32k 入 /128 出、 1024 KV tokens/ 层，预热后五次均值。
质量： LongBench16 任务， 512 KV tokens/ 层；与效率预算不同。

TTFT	**未找到独立结果；论文只报告端到端总时延。**
TPOT	**未找到独立结果；总时延 11.562s 不能除以 128 当作 TPOT 。**
内存	**上述效率配置峰值 22.84 GiB ； 缺 Full KV 同口径原值，无法算下降比例。**
质量	**512 tokens/ 层： Full KV 49.77→48.37 ， – 1.40 分，相对损失 2.81% 。**

64 tokens/ 层： DeferKV 43.97 优于 LAQ 42.45 ， 但仍低于 Full KV 49.77 。

查看实验原表 →

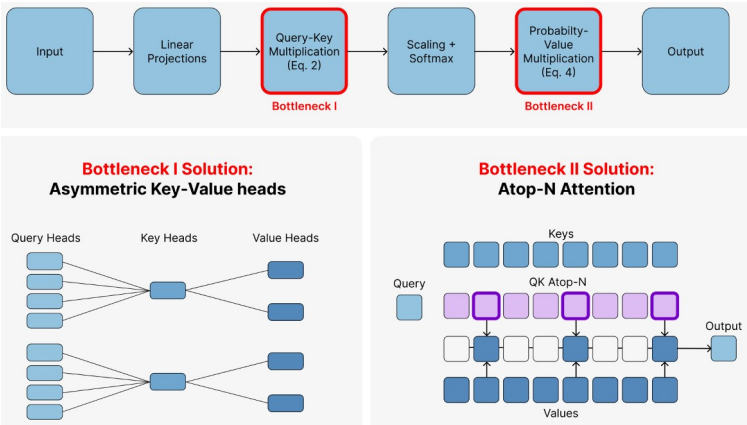


研究判断 将“首个 decode 反馈 + 时间加权”接入现有 KV 淘汰器，固定业务集扫描每层保留预算，并分开记录首个 decode 开销与稳态 TPOT 。先达到小于 1% 质量损失，再比较实际显存和时延，避免用极小预算换取失真结果。

SAGA： 少读 Key 、只算重要 Value ， 分两段降低解码开销

稀疏 Attention 减少 Value 计算后， Key 读取成为剩余瓶颈，精确排序还会吞掉收益。 SAGA 合并 Key 头而保留 Value 头，再用周期阈值实现近似 Top-N ， 分别减少 Key 读取与 Value 访问。

关键技术 | 核心思路与实现方法



Key 头合并： 用原模型的 Query 衡量 Key 头合并后的注意力分数误差，选择误差小的配对；合并 Key 投影，保持 Value 头数不变。

近似 Top-N ： 定期求一次第 N 大注意力概率作为阈值，后续用逐项比较筛选 Value ； 省去每步精确排序，但选择的是近似 Top-N 。

蒸馏恢复质量： 合并后用教师输出的 KL 损失和真实标签交叉熵微调，让模型适应较少 Key 头；它有训练成本，不能当作纯运行时开关。

关键效果 | 基线 → 论文方案

性能： Llama3.2-1B ， H100 ； 64k 上下文、 batch16 ； CUDA graphs 。
Key 头 8→4 ， Value 保持 8 ， Atop-N=1024 ； 32 步解码 ×10 次。
质量：同模型 HellaSwag 仅比较架构蒸馏，不含 Atop-N 联合效果。

TTFT	**未找到实测；论文聚焦 decode 阶段。**
解码	**逐 token 微基准 40.57→18.99 ms （– 53.2% ） 服务 TPOT 未单列，不等同完整服务收益**
内存	**未报告 GiB ； 已合并层 KV 按头数推算少 25% ， 排除豁免层和临时空间，非实测。**
质量	**Llama3.2-1B HellaSwag： GQA 64.3%→SAGA 58.3% ， – 6.0 个百分点。**

Qwen2.5-32B 扩展仅未训练架构计时，没有质量结果；不可当作 27B 业务收益。

查看实验原表 →

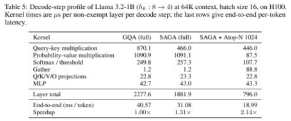


Table 5: Decode-step profile of Llama 3.2-1B ($h_q : 8 \to 4$) at 64K context, batch size 16, on H100. Kernel times are μs per non-exempt layer per decode step; the last rows give end-to-end per-token latency.

Kernel	GQA (full)	SAGA (full)	SAGA + Atop-N 1024
Query-key multiplication	870.1	466.0	446.0
Probability-value multiplication	1090.9	1091.1	87.5
Softmax / threshold	249.8	257.3	107.7
Gather	1.2	1.2	88.8
QK/V/O projections	22.8	23.3	22.8
MLP	42.7	43.0	43.3
Layer total	2277.6	1881.9	796.0
End-to-end (ms / token)	40.57	31.08	18.99
Speedup	1.00×	1.31×	2.14×

研究判断 把无需训练的 Atop-N 与需要蒸馏的 Key 头合并分开试验，先扫描稀疏 N ， 再决定是否改模型结构。长上下文业务质量损失必须小于 1% ， 并以昇腾同并发下的 TTFT 、 TPOT 及实际显存确认收益。

AlignQuant ｜原始测试条件与结果

Metric	Unit	Upper Ref.	Lower Ref.	Ours	Others			
		BF16	W4A8	*AlignQuant*	GPTQ	AWQ	MixLLM	SFMP
TTFT ↓	ms	17.47	22.51	**19.67**	21.99	23.07	27.48	86.99
TPOT ↓	ms/token	17.19	21.12	**7.54**	20.77	21.78	24.05	82.33
Throughput ↑	tok/s	58.18	47.33	**132.28**	48.13	45.91	41.58	12.15
Resident GPU Mem. ↓	GiB	5.99	2.08	2.72	**2.11**	2.12	2.87	2.15
Peak VRAM ↓	GiB	6.09	2.16	2.72	**2.20**	2.21	2.92	2.37
Energy ↓	J/1K tokens	2280.68	2322.34	**1267.92**	2047.43	1732.24	2172.71	22535.65

Llama-3.2-3B-Instruct ｜ A100 40GB ｜ BF16 对照
B=1； 输入 128 / 输出 512 tokens； 60% W4 + 40% W8
质量： WikiText-2 及 MMLU 等 6 任务；系统负载未列文本集。

← 返回第 4 页：技术与研究判断

SpAx ｜原始测试条件与结果

				CPU memory			Flash			
		needed (GB)	GPU (ms)	transfer (ms)	other (ms)	total (ms)	moved (GB)	transfer (ms)	other (ms)	total (ms)
QWEN-CA-BF16	Dense	34.23	58	2,739	35	2,832	34.23	5,485	109	5,652
	TEAL +10%	14.41	25	1,156	56	1,236	14.90	2,452	205	2,682
	SpAx-trellis +10%	3.78	145	303	60	508	4.62	836	193	1,174
	SpAx-scalar +10%	6.87	44	551	65	660	7.79	1,374	230	1,648
QWEN-CA-Q4KM	Dense	10.36	42	830	25	897	10.36	1,848	87	1,978
	TEAL +10%	4.36	15	352	44	411	5.60	1,038	121	1,174
	SpAx-trellis +10%	2.60	100	209	46	355	3.76	747	126	973
	SpAx-scalar +10%	3.12	26	251	50	328	4.57	925	112	1,063

如何读这张表

Qwen3.6-27B ｜ RTX4090 / PCIe4.0×8 ｜ B=1

仅 FFN 从 CPU 卸载； Dense BF16 vs trellis 近似（ +10% PPL 容忍）

4 步预热 + 8 步解码；输入长度未报告。质量另见 Table 10 。

SSD 实搬 34.23→4.62 GB/token （– 86.5% ）； 减少搬运不能等同减少显存或模型总存储。

← 返回第 12 页：技术与研究判断

TaSQ ｜原始测试条件与结果

Table 2: Long-CoT reasoning performance under low-bit KV cache quantization. We report the mean and standard deviation over three seeds. Bold denotes the best quantized result; higher is better.

Model	Method	Bits (K/V)	AIME'24	AIME'25	LCB-v6	SciBench	Avg.
Qwen3-4B-Thinking-2507	BF16	16.000/16.000	74.44±1.92	74.44±5.09	45.85±0.62	73.99±0.43	67.18±1.37
	CQ	1.250/1.250	26.67±3.33	14.44±5.09	18.99±0.44	54.00±0.94	28.52±1.54
	NovaKV	1.375/1.250	7.78±1.92	6.67±3.33	9.16±0.38	27.94±2.08	12.89±1.10
	NSNQuant	1.238/1.238	44.44±6.94	38.89±1.92	34.66±0.33	68.69±0.55	46.67±1.81
	TaSQ	1.266/1.250	**68.89±1.92**	**56.67±3.33**	**43.00±0.47**	**73.65±0.60**	**60.55±0.98**

性能： Qwen3-4B-Thinking-2507 ， 单卡 RTX 6000 Ada ， SGLang 。
吞吐： 2k 入 /32k 出； TTFT ： 8k–32k 输入、 batch=1 。
质量：同模型， AIME24/25 、 LCB-v6 、 SciBench 三种子均分；性能分测。

← 返回第 13 页：技术与研究判断

Page-EntroKV ｜原始测试条件与结果

Table 6: Needle retrieval under two success criteria (Qwen2.5-1.5B pilot, matched 20% physical budget). Pooled-selection criterion: retention requires the needle's page to survive the pooled eviction decision (no cross-layer requirement). Strict all-layer criterion: the needle's page must survive in every layer. Asterisk: weighted recall at depth 0 spans 0–33% across strict-variant runs. All zero cells verified as genuine evictions (30/30).

(a) Pooled-selection criterion

Context T	959	1469	1989	2499
Arithmetic mean	0.0%	0.0%	0.0%	0.0%
Page-EntroKV	**100.0%**	**100.0%**	**100.0%**	**100.0%**

(b) Strict all-layer criterion (recall by needle depth)

Method	0%	25%	50%	75% / 100%
Uncompressed	1.00	1.00	1.00	1.00 / 1.00
Mean pooling (page)	0.00	0.00	0.00	0.00 / 1.00
Page-EntroKV	0–0.33*	0.00	0.00	0.00 / 1.00

如何读这张表

Qwen2.5-1.5B-Instruct；单卡 T4； HF eager，逻辑分页 16 tokens。

pilot 上下文约 0.9k–8.2k；检索测试≤ 2.5k，保留预算 20%。

A100/vLLM/128k 是后续计划，尚非已测配置。

LongBench 仅 4×20 例，缺 Full KV 同口径基线；不能计算精度损失，也不能宣称无损。

← 返回第 14 页：技术与研究判断

AttSVD | 原始测试条件与结果

Table 1: Measured KV-cache memory on Phi-4-14B (40 layers, 40 query / 10 KV heads) and Qwen3-8B (36 layers, 32 query / 8 KV heads); d=128, bf16.

		Phi-4-14B			Qwen3-8B		
	Rank r	KV @32K (GiB)	Measured ratio	KV @9.4K (GiB)	KV @32K (GiB)	Measured ratio	KV @9.4K (GiB)
Dense cache	128	6.250	1.000	1.804	4.500	1.000	1.299
AttSVD (c=0.50)	64	3.139	0.502	0.916	2.260	0.502	0.660
AttSVD (c=0.75)	32	1.571	0.251	0.459	1.131	0.251	0.330
AttSVD (c=0.875)	16	0.787	0.126	0.231	0.567	0.126	0.166

Qwen3-8B， BF16 、 rank64； KV 内存测试 32k 上下文。
质量： LongBench 九任务、 1750 例， 50% 缓存；与内存分测。
全文未找到明确 GPU 型号、 batch 及分项时延结果。

← 返回第 6 页：技术与研究判断

StagQ | 原始测试条件与结果

Method	Bit	Rate	MMLU	ARC-C	ARC-E	HS	PIQA	WG	CSR Avg
bfloat16	16	16.00	65.23	53.67	81.06	78.91	81.28	73.72	73.73
MatGPTQ	2	2.25	24.65	24.74	24.45	26.29	51.41	49.17	35.21
Any-Precision	2	2.01	23.82	24.57	34.09	27.90	57.24	50.36	38.83
AnyBCQ	2	2.38	35.33	37.29	62.67	62.76	73.94	57.93	58.92
StagQ-XXS	2	2.35	38.38	38.05	60.94	63.63	73.23	65.27	60.23
StagQ-XS	2	2.64	**48.67**	**41.98**	**70.12**	**70.05**	**75.52**	**67.32**	**65.00**

质量： Llama-3.1-8B ； StagQ-XXS 2-bit / 2.35 bpw
对照 AnyBCQ 2.38 bpw 与原始 BF16 ； MMLU 5-shot / WT2
执行实验： A100 、 B=1 、合成权重，不能视作真实模型收益。

← 返回第 15 页：技术与研究判断

DBW | 原始测试条件与结果

Type	Method (Bit)	LLaMA-7B				LLaMA-2-7B				LLaMA-3-8B			
		Ratio	*Mem*	*PPL*↓	*Acc.*↑	*Ratio*	*Mem*	*PPL*↓	*Acc.*↑	*Ratio*	*Mem*	*PPL*↓	*Acc.*↑
-	Baseline (FP16)	0.00	12.31	6.38	63.06	0.00	12.31	6.22	63.19	0.00	13.98	7.51	65.98
sequential optimization	ASVD (FP16)	46.33	6.72	3.0e4	25.02	46.33	6.72	4.5e4	23.94	46.33	7.96	2.6e4	24.43
	ASVD+GPTQ (1.61)	46.33	1.56	3.0e4	25.00	46.33	1.56	4.5e4	24.63	46.33	2.40	2.6e4	24.26
	ASVD+OmniQ (1.61)	46.33	1.56	3.1e4	25.02	46.33	1.56	8.9e4	24.89	46.33	2.40	5.3e4	24.97
	SVD-LLM (FP16)	46.33	6.72	14.08	47.21	46.33	6.72	59.28	31.59	46.33	7.96	53.76	36.55
	SVD-LLM+GPTQ (1.61)	46.33	1.56	22.45	37.17	46.33	1.56	116.38	27.80	46.33	2.40	102.31	30.26
	SVD-LLM+OmniQ (1.61)	46.33	1.56	17.22	42.84	46.33	1.56	77.10	29.35	46.33	2.40	89.41	30.52
co-optimization (our DBW) (1.61)		47.21	1.56	10.65	48.98	46.95	1.56	10.54	49.06	44.71	2.40	19.38	44.38

Table 5: **Sequential vs. co-optimization of pruning and quantization.** We evaluate compression methods using SVD with PTQ approaches. ASVD and SVD-LLM apply the sequential optimization of pruning and quantization, while ours co-optimizes them concurrently. Note that methods in parentheses with FP16 denote the pruning-only results. We report the average perplexity (*PPL*↓) of the WikiText-2 and C4 datasets and the mean accuracy (*Acc.*↑) on the eight commonsense benchmarks. *Mem* is the memory footprint (GB) of the compressed model. For a controlled comparison, we match the pruning *Ratio* and bit-width of the baselines to those of DBW, providing more results in §D.3.

如何读这张表

LLaMA-2-7B | 1.61 bpw； group=128 | FP16 对照

校准 RedPajama 4096×2048； 测试 WT2/C4 + 8 项零样本

权重字节和质量为模型级； RTX3090 内核测时是另一实验。

图中 Table 5 的 PPL 6.22→10.54 为 WikiText-2/C4 均值；正文 Table 2 的 5.47→8.78 仅为 WikiText-2 。

← 返回第 16 页：技术与研究判断

Align, Then Correct ｜原始测试条件与结果

Method	3 bits			4 bits		
	WT2	C4	CSQA	WT2	C4	CSQA
FP16	9.73	15.24	69.38	9.73	15.24	69.38
QuIP#	10.48	16.30	68.10	9.99	15.54	68.83
+ EoRA	10.37	16.22	68.54	9.94	15.53	68.76
+ QERA	10.38	16.21	68.55	9.95	15.53	68.91
+ ProjQ	10.36	16.21	68.49	9.96	15.55	68.84
+ LQ-LoRA	10.24	15.90	68.22	9.87	15.46	69.00
+ Ours	**8.54**	**14.56**	**69.11**	**8.22**	**14.15**	**69.41**

Table 2: Qwen3-8B across bit-widths: WikiText-2 and C4 perplexity (↓) and CSQA Avg (↑). The gain persists at every bit-width and on both corpora, including the held-out C4. Best per bit-width in **bold**; the FP16 row is a reference and is excluded.

如何读这张表

Qwen3-8B ｜ A100 40GB ｜ QuIP# 3-bit + rank64

对照原 QuIP# 3-bit 及 FP16； WT2/C4 、 7 项常识零样本

校准：第一阶段 128×2048 ，第二阶段 16×512 tokens 。

2-bit 常识均分 64.51% ， 不能拿 2-bit 体积配 3-bit 精度； 2-bit 离线构建约 63 分钟。

← 返回第 5 页：技术与研究判断

DeferKV ｜原始测试条件与结果

Method	Single-Doc QA			Multi-Doc QA			Summ.			Few-Shot			Synth.		Code		Avg.
	NrtvQA	Qasper	MF-en	HotpotQA	2WikiMQA	MuSiQue	GovReport	QMSum	MultiNews	TREC	TriviaQA	SAMSum	PCount	PR-en	LCC	RB-P	
Qwen3-8B, $B_{\text{total}} = 64L$																	
SnapKV	17.41	30.06	38.05	47.77	37.71	20.65	14.00	19.37	12.93	43.50	81.92	36.53	5.00	87.50	59.30	53.58	37.83
LAQ	18.99	**37.88**	43.31	53.88	41.35	23.24	**16.18**	19.40	14.78	66.00	88.40	**37.64**	5.50	94.50	62.31	55.91	42.45
SpecKV	19.61	29.97	**49.79**	51.03	36.97	22.14	13.27	**19.72**	**14.82**	37.50	73.63	36.71	6.00	95.00	45.15	46.62	37.37
LookaheadKV	18.22	32.27	40.12	47.66	38.01	23.58	14.61	18.36	13.18	46.95	83.29	36.69	5.00	90.40	59.06	54.28	38.86
DeferKV	**21.87**	35.37	45.97	**56.99**	**41.88**	**31.20**	14.81	19.52	13.52	**70.50**	**89.98**	37.44	**8.00**	**97.50**	**62.52**	**56.47**	**43.97**
Qwen3-8B, $B_{\text{total}} = 512L$																	
SnapKV	22.70	42.96	51.19	57.09	42.51	**34.94**	25.14	**23.44**	21.87	68.50	89.46	43.34	**9.50**	**100.00**	**68.74**	64.22	47.85
LAQ	23.16	43.58	52.63	56.16	43.02	34.36	25.46	22.02	21.94	71.00	**90.05**	43.35	**9.50**	**100.00**	67.92	64.72	48.05
SpecKV	24.38	43.27	**53.93**	58.07	42.90	31.48	**29.51**	23.24	**24.05**	71.00	89.96	29.60	4.00	99.00	56.84	56.85	46.13
LookaheadKV	23.10	43.67	52.21	56.86	43.12	34.91	25.46	22.71	22.08	71.00	89.97	**43.85**	**9.50**	99.00	68.01	**64.98**	48.15
DeferKV	**24.82**	**44.78**	51.96	**58.09**	**43.18**	33.83	26.04	22.74	22.17	**71.50**	**90.05**	43.70	**9.50**	**100.00**	67.55	64.02	**48.37**
Full KV	24.73	48.05	54.39	58.16	43.79	34.27	33.45	24.12	24.84	71.50	90.21	44.56	9.50	100.00	69.34	65.48	49.77

如何读这张表

Qwen3-8B； A100 80GB； batch=1 、贪心解码。

效率： 32k 入 /128 出、 1024 KV tokens/ 层，预热后五次均值。

质量： LongBench16 任务， 512 KV tokens/ 层；与效率预算不同。

64 tokens/ 层： DeferKV 43.97 优于 LAQ 42.45 ， 但仍低于 Full KV 49.77 。

← 返回第 17 页：技术与研究判断

SAGA ｜原始测试条件与结果

Table 5: Decode-step profile of Llama 3.2-1B ($h_k : 8 \rightarrow 4$) at 64K context, batch size 16, on H100. Kernel times are μs per non-exempt layer per decode step; the last rows give end-to-end per-token latency.

Kernel	GQA (full)	SAGA (full)	SAGA + Atop-N 1024
Query-key multiplication	870.1	466.0	446.0
Probability-value multiplication	1090.9	1091.1	87.5
Softmax / threshold	249.8	257.3	107.7
Gather	1.2	1.2	88.8
Q/K/V/O projections	22.8	23.3	22.8
MLP	42.7	43.0	43.3
Layer total	2277.6	1881.9	796.0
End-to-end (ms / token)	40.57	31.08	18.99
Speedup	1.00×	1.31×	2.14×

如何读这张表

性能： Llama3.2-1B， H100； 64k 上下文、batch16； CUDA graphs 。

Key 头 8→4， Value 保持 8， Atop-N=1024； 32 步解码 ×10 次。

质量：同模型 HellaSwag 仅比较架构蒸馏，不含 Atop-N 联合效果。

Qwen2.5-32B 扩展仅未训练架构计时，没有质量结果；不可当作 27B 业务收益。

← 返回第 18 页：技术与研究判断

Mistral Large 4：万亿参数 MoE 把权重容量推到前台

2026-10-06 · Mistral 官方预览公告 · 关联技术地图：权重 × 量化

01 发生了什么 • 原始事实

01 模型规模

官方披露 1T 总参数、 52B 激活参数；两者分别描述模型规模与稀疏激活规模。

02 开放状态

预览 API 已开放；权重计划月底发布。截止核对时，不把开放计划写成已交付。

03 研究窗口

权重和架构细节尚待发布；当前不能复核专家布局、可量化层或部署格式。

02 为什么重要 • 研究分析

容量预算：总权重仍需有去处

52B 激活参数不能替代总参数容量账。需区分全量驻留、专家分层存储、每 token 搬运与通信成本。

技术选择：量化与驻留要共同设计

专家权重量化可减小存储与搬运字节，但收益取决于路由命中、解码开销和并行划分，不能只按名义位宽排名。

03 观点与建议

先列入权重 × 量化跟踪；等权重公开后，优先核对专家格式与驻留预算，再决定是否投入适配。

证据边界：厂商规格与发布计划；容量与路线取舍为分析判断。未证明压缩收益或昇腾支持。

[H1] Mistral 官方公告 · Preview / Frontier performance

openTPU： 低比特要看总字节、质量与端到端收益

2026-10-01 作者实验 · build B · Kintex-7 PCIe 板卡 · 权重 × 量化

01 发生了什么 • 原始事实

01 编码成本

4-bit 权重采用两级块尺度；计入尺度后为 4.25 bit/weight，LM head 保留 INT8。

02 可比结果

Qwen3.5-2B： INT8 / 4-bit 的 wall 解码速度为 8.00 / 12.03 tok/s。

03 测量条件

512-token prompt、 64 greedy tokens； device 与 wall 分开计， DRAM 流量由板卡计数器读取。

02 为什么重要 • 研究分析

名义压缩率不能代替实际收益

12.03 / 8.00 约为 1.50 倍（计算值）；不能按位宽减半直接宣称两倍加速。尺度、保留层和反量化都要计费。

评测口径值得迁移，硬件倍数不能迁移

在昇腾报告总权重字节、端到端时延及质量变化。作者说明量化存在 PPL 代价，模拟器逐位一致不等于全精度质量无损。

03 观点与建议

把它作为量化评测口径参考；在同模型、同负载、同质量约束下比较昇腾基线，不照搬 FPGA 加速倍数。

证据边界：项目作者自测； 10-01 为实验日。上述比值由原表计算，未进行昇腾复现。

[H2] openTPU README · Results / Method / 4-bit encoding

Strands Decider 2B： 先缩小任务职责，再压缩模型

2026-10-01 · Strands 官方开源介绍 · 相邻研究背景，非剪枝或蒸馏成果

01 发生了什么 • 原始事实

01 模型改造

以 Qwen3.5-2B 为主干，替换 LM head 为 pointer head，用 rank-16 LoRA 微调。

02 任务边界

一次前向对给定选项打分；不能生成通用文本，不适合直接替代聊天、编码和摘要模型。

03 可研究性

官方开放代码、权重、训练数据与脚本；评测关注准确率、置信度校准与决策延迟。

02 为什么重要 • 研究分析

压缩前先问：业务是否需要通用生成

分类、路由和选项决策可评估任务专用模型。改变任务职责与降低数值精度是两种取舍，收益不能混在一个压缩指标里。

研究顺序：先形成任务基线，再量化

若专用模型满足业务准确率，再评估低比特质量损失与服务成本。无法承担的复杂推理仍交给通用模型。

03 观点与建议

路由业务可单列试验：先测决策准确率、校准与 P95 延迟，再判断是否量化；不纳入剪枝 / 蒸馏已实现清单。

证据边界：官方架构与开源披露；昇腾适配和本地延迟未确认。不可用生成质量评测替代决策质量。

[H3] Strands · Model Architecture / Limitations / Performance

msModelSlim： 模型 × 量化模式开始形成明确交付项

本月核对既有文档 · 26.0.0.alpha02 为内测版，发布日期未列 · 权重 / 激活 × 量化

01 发生了什么 • 原始事实

01 具体模型与模式

alpha02 列示 Qwen3-Coder-480B W4A8 、 Qwen3.5 MoE W8A8 与 GLM-5 W4A8 。

02 接入与调优变化

版本说明新增自定义 practice 目录的 entry point ， 构建 model_adapter 插件化基础，并优化自动调优。

03 算法与版本分开

V1 算法文档列出 GPTQ 、 AWQ 、 FA3 Quant 、 KVCache Quant ； 不把目录收录当作全部模型已支持。

02 为什么重要 • 研究分析

论文比较应站在可交付基线上

权重量化研究先确认目标模型能导出何种格式，再与 GPTQ / AWQ 等已支持路径比较；相同位宽仍可能因布局而不能互换。

低精度能力落地依赖三重匹配

模型实践、量化输出、推理引擎要一致。自动调优可形成质量基线，但“工具支持”不能代替算子可执行或真实加速证明。

03 观点与建议

先用目标模型已支持的配置建立质量与容量基线；新论文只有在同总字节、同负载下有增量价值时才投入适配。

证据边界：官方文档， 2026-10-09 复核； alpha02 非正式版、非确认的十月新发布；部署依模型实践核对。

[I1a] msModelSlim · 版本说明 / alpha02 [I1b] V1 算法总览

量化 Attention：低精主体与高精尾块需要联合核算

ops-transformer 主干公开目录 · 2026-10-09 复核 · KV Cache × 量化；关联激活 × 量化

01 发生了什么 • 原始事实

01 高精窗口接口

主干说明将 quant_flash_attn 从 15 输入扩至 18 输入，新增 v_tail 尾块高精窗口及配套元数据。

02 布局正确性修复

提交 26716275 描述真实 stride 传入地址计算，修复非连续 v_tail 被按连续布局寻址导致的精度错误。

03 可用范围待核对

目录说明在 CANN 9.2 TensorV2 环境验证； CANN 9.1 有既有版本检查限制。正式发布标签尚待确认。

02 为什么重要 • 研究分析

混合精度缓存：保质量也增加容量

高精尾块意味着不能把全部 KV 都按 MXFP8 计算。比较缓存总字节时，要纳入尾块、尺度与布局元数据。

论文方案与工程路径的连接点

KV 量化论文若需要高精残差窗口，可优先核对已有尾块接口；窗口策略、布局检查和 Attention 合计时延仍需验证。

03 观点与建议

把高精尾块列为 KV 量化的工程候选；先核对合法布局、窗口字节与版本，再测质量—容量—时延的取舍。

证据边界：主干目录公开变更说明；未重跑项目测试，提交精确日期未确认；主干能力不等于安装包已发布。

[I2] quant_flash_attn · 主干目录与提交描述

vLLM-Ascend 候选版：低精度支持必须细到模型和层

v0.27.1rc1 · 说明日期 09-24 / GitHub 发布 09-29 · 权重 / 激活 / KV Cache × 量化

01 发生了什么 • 原始事实

01 模型和硬件限定

MiniMax-M3 覆盖 Atlas 800 A3 、 950DT ； DeepSeek-V4-Flash 覆盖 950DT 。 A2 未充分验证。

02 量化路径不是全层同精度

MiniMax-M3 新增 W8A8 与 ModelOpt 兼容 MXFP8 ；fp8 缓存开关下， MSA / index 为 FP8 ， dense GQA 默认 BF16 。

03 配套基线明确

发布镜像配套 vLLM 0.27.1 、 CANN 9.1.0 、 HDK 26.1.1 、PyTorch / torch_npu 2.10.0 系列。

02 为什么重要 • 研究分析

容量估计必须按层计算

全模型缓存不能统一按 C8 估算。要读取实际缓存类型、BF16 回退与各层占比，再计算并发容量。

算子和调度改变收益兑现方式

发布说明含稀疏 Attention 、索引与 TP 通信变化；研究比较要固定完整镜像，区分数值压缩收益与运行栈优化收益。

03 观点与建议

仅在声明支持的模型 / 硬件组合建立候选基线；先确认逐层 dtype 和回退，再测同质量与 SLA 下的容量及 TPOT 。

证据边界：官方候选发布说明；不是正式版或十月新发布，不代表 A2 等范围外组合可用；未有昇腾本地实测。

[I3] vLLM-Ascend v0.27.1rc1 · Features / Scope / Dependencies

vLLM-Ascend 正式补丁：压缩收益先过正确性门槛

v0.23.0.post1 · 说明日期 09-21 / GitHub 发布 09-22 · 既有补丁，本月复核

01 发生了什么 • 原始事实

01 KV 写入修复

DP 对齐 dummy run 前使各 KV group 的 slot mapping 失效，修复陈旧 KV-cache 写入。

02 量化缓冲区稳定性

修复 Atlas 300I DUO 的 MTP overlay 前缀缓存精度； ACL Graph 下 RL 重载时保持 W8A8 MXFP8 转换缓冲稳定。

03 KV Pool 依赖固定

锁定 memfabric_hybrid 与 memcache_hybrid 为 1.2.0；这些修复分属各自执行条件。

02 为什么重要 • 研究分析

错误复用会伪装成量化质量损失

KV 写入、前缀复用和权重重载的问题可能污染质量比较。应先排除状态错误，再归因于量化误差。

基线要包含真实生命周期

单次静态推理不足以覆盖复用、重载和分布式路径。仅对业务使用的路径补充回归，避免把相关补丁泛化为所有模型收益。

03 观点与建议 **现网涉及上述路径时，先评估补丁基线并回归正确性；确认结果一致后，再比较论文方案的净性能收益。**

证据边界：官方 Bug Fixes 与依赖变更；精度修复不等于吞吐提升，正式补丁也不证明所有模型 / 硬件可用。

[I4] vLLM-Ascend v0.23.0.post1 · Bug Fixes / Other Changes

阅读口径｜技术有效，不代表所有指标都改善

本报告保留学术进展 → 热点资讯 → 产业动态 → 研究判断的主线。每项技术分别回答：省什么、快在哪里、质量损失多少，再判断是否值得迁移到业务。

TTFT： 首词时延

固定模型、输入长度与 batch ，记录首个输出 token 耗时；预处理和在线量化造成的增加也必须展示。

TPOT： 逐词时延

优先使用论文直接报告的 TPOT 。逐 token 解码微基准另行标注；吞吐量、总时延均不能替代。

内存：先明确范围

区分权重存储、 KV 张量、驻留 GPU 内存与峰值 HBM 。只给保留比例或位宽时，不能宣传为实测显存降幅。

精度：同时看两种基线

既比较压缩方法，也对照原模型。准确率百分点与相对百分比分开；PPL 和 LongBench 分数不等于业务精度。

业务目标： LLM （以 Qwen3.8-27B 为例）与降噪、翻译等领域模型； 310P / 910B / 950 （具体型号未确认）。质量损失须低于 1% ，同时追求高吞吐、低时延；本报告不把 GPU 论文结果当作昇腾实测。

材料窗口截至 2026-10-09 ； 本次复核 2026-10-15 。全部数值保留原测试条件；缺失项明确写“未报告” 。